

Nombre del proyecto
Análisis comparativo de modelos de aprendizaje automático y arquitecturas Transformer para la clasificación de tráfico de red cifrado sobre el dataset CESNET-TLS-Year22

Profesor	Gladys María Villegas Rugel
Materia	Proyecto Integrador en Inteligencia Artificial
Alumno	Jhayya Perlaza Jairo Wladimir
Fecha	22-sep-2026

Resumen del Proyecto
Este proyecto compara cuatro modelos de aprendizaje automático (Random Forest, XGBoost, una red convolucional 1D y un Transformer ligero) para clasificar tráfico de red cifrado en 24 categorías de servicio, usando solo los metadatos de cada conexión y nunca su contenido. El trabajo se apoya en CESNET-TLS-Year22, un dataset público capturado durante todo 2022 en una red real, y mide tanto la precisión de cada modelo como lo que cuesta ejecutarlo. Los resultados se podrán revisar y ejecutar en una aplicación web hecha en Streamlit. El trabajo es individual y se organiza con Scrum en cuatro sprints durante seis semanas.

Actividad	Fecha
– Mapa del estado del arte: revisión bibliográfica y posicionamiento de la propuesta. – Análisis de los datasets disponibles. – Definición de métricas de éxito (matriz de KPIs). – Análisis de stakeholders. – Documento de alcance del proyecto (Canvas SMART). – Cronograma con metodología ágil (Scrum). – Plan de recursos. – Hitos y entregables.	22-sep-2026

Índice general

Introducción	3
2. Desarrollo	4
2.1 Información del proyecto	4
2.1.1 Roles Scrum y responsabilidades	4
2.2 Mapa del estado del arte.....	4
2.2.1 Cómo se hizo la revisión.....	4
2.2.2 Fuentes revisadas	5
2.2.3 Enfoques principales	6
2.2.4 Evolución del área	7
2.2.5 Gap identificado y posicionamiento	8
2.3 Análisis de datasets disponibles	9
2.3.1 Datasets evaluados	9
2.3.2 Comparación y recomendación	10
2.3.3 Plan de adquisición y preprocesamiento	10
2.4 Definición de métricas de éxito	11
2.4.1 Métricas técnicas	11
2.4.2 Métricas de impacto, adopción y satisfacción	12
2.4.3 KPIs seleccionados y seguimiento	12
2.5 Análisis de stakeholders	13
2.6 Documento de alcance del proyecto	14
2.6.1 Objetivo general.....	14
2.6.2 Objetivos específicos	15
2.6.3 Alcance incluido	15
2.6.4 Alcance excluido	16
2.6.5 Criterios de aceptación	16
2.6.6 Supuestos y restricciones	16
2.7 Cronograma con metodología ágil (Scrum).....	17
2.7.1 Ceremonias y artefactos	17
2.7.2 Product Backlog priorizado	17
2.7.3 Planificación de sprints	18
2.7.4 Matriz de riesgos	20
2.8 Plan de recursos	20
2.8.1 Recursos humanos	20
2.8.2 Recursos técnicos	21
2.8.3 Recursos financieros	21
2.9 Hitos y entregables	22
Conclusiones	24
Referencias bibliográficas	25
ANEXOS.....	28

Introducción

Hoy casi todo lo que viaja por Internet va cifrado. TLS 1.3 y QUIC protegen la privacidad de los usuarios, y eso es una buena noticia, pero también dejaron casi sin utilidad a las herramientas de inspección profunda de paquetes que usaban los proveedores y las empresas para saber qué pasaba en sus redes. Si el contenido ya no se puede leer, lo único que queda es observar cómo se comporta cada conexión: cuánto pesan sus paquetes, en qué dirección van y cada cuánto tiempo aparecen.

Con esos datos se pueden entrenar modelos de aprendizaje automático, y la literatura de los últimos años está llena de propuestas que reportan exactitudes cercanas al 100 %. Al revisarla con calma aparecen dos problemas. El primero es que muchas de esas cifras salen de datasets antiguos, divididos al azar y con acceso al contenido de los paquetes, algo que infla los resultados [8], [13], [14]. El segundo es que el tráfico real cambia de un mes a otro y los modelos pierden precisión con rapidez [10], [11].

De ahí nace la pregunta que guía este proyecto: si solo contamos con los metadatos de cada flujo, ¿qué conviene más, un modelo clásico y barato como Random Forest o una red profunda con mecanismos de atención? Para responderla comparo cuatro modelos sobre CESNET-TLS-Year22 [1], un dataset que registra un año completo de tráfico de una red en producción, usando una partición por meses y midiendo, además del desempeño, el costo computacional de cada opción. Este documento presenta la planificación completa: estado del arte, datasets, métricas, stakeholders, alcance, cronograma, recursos e hitos.

2. Desarrollo

2.1 Información del proyecto

Título:	Análisis comparativo de modelos de aprendizaje automático y arquitecturas Transformer para la clasificación de tráfico de red cifrado sobre el dataset CESNET-TLS-Year22
Dominio:	Ciberseguridad y gestión de redes
Modalidad:	Individual
Autor:	Jairo Wladimir Jhayya Perlaza
Duración:	6 semanas, del 28 de septiembre al 8 de noviembre de 2026, en 4 sprints
Fecha de entrega:	22 de septiembre de 2026

2.1.1 Roles Scrum y responsabilidades

Como el proyecto es individual, los tres roles de Scrum recaen en la misma persona. Prefiero declararlo desde el inicio en lugar de simular un equipo que no existe. El docente de la asignatura cumple una función clave: es quien revisa cada incremento al cierre de los sprints.

Tabla 1

Roles Scrum y responsabilidades en el proyecto

Rol	Responsable	Responsabilidades principales
Product Owner	Jairo Jhayya Perlaza	Mantener y priorizar el Product Backlog; definir criterios de aceptación; decidir qué entra en cada sprint
Scrum Master	Jairo Jhayya Perlaza	Cuidar que se cumplan las ceremonias; registrar impedimentos; proteger el alcance comprometido
Development Team	Jairo Jhayya Perlaza	Preparar los datos, entrenar y evaluar los modelos, desarrollar y desplegar la aplicación web
Stakeholder principal	Docente del Proyecto Integrador	Validar el alcance y revisar el incremento en cada Sprint Review

La tabla nro. 1 resume cómo se reparten los roles. En un proyecto de una sola persona el riesgo no está en los conflictos de autoridad sino en la sobrecarga, por eso la revisión externa del docente en cada cierre de sprint funciona como el contrapeso que en un equipo daría el Product Owner frente a los desarrolladores.

2.2 Mapa del estado del arte

2.2.1 Cómo se hizo la revisión

Busqué en IEEE Xplore, ACM Digital Library, SpringerLink, ScienceDirect, Nature Portfolio y arXiv, además de revisar las publicaciones del grupo CESNET, que es el autor del dataset. Usé combinaciones de términos como «encrypted

traffic classification», «TLS/QUIC traffic classification», «packet sequence» y «data drift network traffic». Acepté trabajos publicados entre 2021 y 2026 en revistas indexadas, en conferencias reconocidas (SIGCOMM, CCS, WWW, IEEE S&P, AAAI, ICNP, TMA) o como preprints de grupos con trayectoria en el tema. Dejé fuera los estudios dedicados solo a detección de intrusiones. El resultado son 31 fuentes recientes, a las que se suman 9 referencias clásicas sobre algoritmos, pruebas estadísticas y herramientas.

2.2.2 Fuentes revisadas

Tabla 2

Registro de fuentes revisadas (2021–2026)

#	Autor(es) y año	Título (abreviado)	Fuente	Tipo
1	Hynek et al., 2024	CESNET-TLS-Year22: a year-spanning TLS dataset	Scientific Data	Revista
2	Hynek et al., 2024	CESNET-TLS-Year22 (registro del dataset)	Zenodo	Dataset
3	Luxemburk y Čejka, 2023	Fine-grained TLS services classification with reject option	Computer Networks	Revista
4	Luxemburk y Čejka, 2023	CESNET-TLS22 (registro del dataset)	Zenodo	Dataset
5	Luxemburk et al., 2023	CESNET-QUIC22: one-month QUIC dataset	Data in Brief	Revista
6	Luxemburk et al., 2023	Encrypted traffic classification: the QUIC case	TMA 2023	Conferenci a
7	Luxemburk y Hynek, 2023	DataZoo: streamlining traffic classification experiments	SAFE 2023 (ACM)	Taller
8	Jerabek et al., 2025	When simple model just works: is TC in crisis?	arXiv	Preprint
9	Pešek et al., 2025	Lightweight traffic classification: a simple baseline	TMA 2025	Conferenci a
10	Soukup et al., 2025	Drift-based dataset stability benchmark	arXiv	Preprint
11	Malekghaini et al., 2023	Deep learning for encrypted TC in the face of data drift	Computer Networks	Revista
12	Malekghaini et al., 2022	Data drift in DL: lessons from encrypted TC	IFIP Networking	Conferenci a
13	Zhao et al., 2025	The sweet danger of sugar: debunking representation learning	ACM SIGCOMM	Conferenci a
14	Wickramasinghe et al., 2025	SoK: decoding encrypted network traffic classifiers	IEEE S&P	Conferenci a
15	Lin et al., 2022	ET-BERT: pre-training transformers for encrypted TC	ACM WWW	Conferenci a
16	Zhao et al., 2023	YaTC: masked autoencoder traffic transformer	AAAI	Conferenci a
17	Zhang et al., 2023	TFE-GNN: temporal fusion encoder with GNN	ACM WWW	Conferenci a
18	Wang et al., 2024	NetMamba: efficient TC via unidirectional Mamba	IEEE ICNP	Conferenci a
19	Yan et al., 2026	NT-Transformer: non-pretrained encrypted TC model	IEEE TNSM	Revista
20	Yang et al., 2025	MM4flow: pre-trained multi-modal traffic model	ACM CCS	Conferenci a
21	Cui et al., 2025	FG-SAT: flow graph under environment shifts	IEEE TIFS	Revista
22	Lin et al., 2025	Instruction-tuning with LLM for non-IID TC	IEEE TIFS	Revista

#	Autor(es) y año	Título (abreviado)	Fuente	Tipo
23	Chen et al., 2025	CD-Net: robust mobile TC against app updates	Computers & Security	Revista
24	Aceto et al., 2021	Distiller: multimodal multitask deep learning	J. Netw. Comput. Appl.	Revista
25	Akbari et al., 2021	A look behind the curtain: TC in an encrypted web	Proc. ACM POMACS	Revista
26	Holland et al., 2021	New directions in automated traffic analysis	ACM CCS	Conferencia
27	Koumar et al., 2024	NetTiSA: extended IP flow with time-series features	Computer Networks	Revista
28	Almuhammadi et al., 2023	QUIC traffic classification with ensemble ML	Applied Sciences	Revista
29	Guerra et al., 2022	Datasets are not enough: labeling network traffic	Computers & Security	Revista
30	Pešek et al., 2023	Active learning for long-term traffic classification	IEEE CCWC	Conferencia
31	Guerra-Manzanares et al., 2025	Review on ML-based VPN detection	Computer Science Review	Revista

La tabla nro. 2 lista las 31 fuentes de los últimos cinco años que sostienen el proyecto. Trece son artículos de revista, trece de conferencia o taller, tres son preprints de grupos consolidados y dos son registros de datasets. Las referencias completas, con su DOI cuando existe, están al final del documento.

2.2.3 Enfoques principales

Tabla 3

Comparación de los enfoques existentes

Enfoque	Técnica y referencias	Fortalezas	Debilidades	¿Sirve para este proyecto?
E1. Modelos clásicos sobre estadísticas y secuencias de flujo	Random Forest, XGBoost, LightGBM, k-NN [8], [9], [27], [28]	Entrenan rápido en CPU y se pueden interpretar; en evaluaciones cuidadosas igualan a los modelos profundos [8], [9]	Piden ingeniería de características; se degradan con la deriva si no se reentrenan [10]	Sí. Son la línea base (Random Forest y XGBoost)
E2. Redes convolucionales y multimodales sobre secuencias	mm-CESNET, Distiller [3], [6], [24]	Aprenden directamente de la secuencia de paquetes; probadas en datasets CESNET	Necesitan GPU; son menos interpretables	Sí. Se implementa una red convolucional 1D
E3. Transformers preentrenados sobre bytes	ET-BERT, YaTC [15], [16]	Exactitud muy alta en datasets clásicos	Dependen del contenido de los paquetes; parte de su desempeño viene de artefactos del payload [13]	No. El dataset no incluye bytes; se citan como referencia
E4. Redes neuronales de grafos	TFE-GNN, FG-SAT [17], [21]	Capturan relaciones entre paquetes; FG-SAT considera cambios de entorno	Complejas; varias usan bytes	Poco. Exceden el plazo de seis semanas
E5. Arquitecturas eficientes y Transformers sin preentrenamiento	NetMamba, NT-Transformer [18], [19]	Inferencia más barata que un Transformer estándar	NetMamba exige GPU especializada y usa bytes	En parte. Inspiran el Transformer ligero

Enfoque	Técnica y referencias	Fortalezas	Debilidades	¿Sirve para este proyecto?
E6. Modelos fundacionales y LLM	MM4flow, ajuste con LLM [20], [22]	Generalizan entre tareas y toleran datos cambiantes	Costo muy alto; difíciles de reproducir con recursos gratuitos	No. Se dejan como trabajo futuro

La tabla nro. 3 agrupa las propuestas en seis enfoques. Lo que más pesa para este proyecto es la última columna: como solo se dispone de metadatos, los enfoques que dependen del contenido de los paquetes quedan fuera, y la comparación se concentra en modelos clásicos, una red convolucional y un Transformer sin preentrenamiento.

Tabla 4

Matriz de fortalezas y debilidades (● alta, ○ media, ○ baja)

Criterio	E1	E2	E3	E4	E5	E6
Desempeño reportado	○	●	●	●	●	●
Robustez ante la deriva temporal	○	○	○	○	○	○
Funciona solo con metadatos	●	●	○	○	○	○
Bajo costo de entrenamiento	●	○	○	○	○	○
Baja latencia de inferencia	●	●	○	○	●	○
Reproducible con recursos gratuitos	●	●	○	○	○	○
Interpretabilidad	●	○	○	○	○	○

La tabla nro. 4 muestra que ningún enfoque gana en todo. Los más recientes reportan mejores cifras, pero a cambio de más cómputo y, varias veces, de información que en una red real a gran escala no está disponible. Los enfoques E1 y E2 son los que mejor encajan con las restricciones del proyecto.

2.2.4 Evolución del área

Tabla 5

Principales avances entre 2021 y 2026

Año	Qué cambió	Referencias
2021	Se documenta que la web ya es mayoritariamente cifrada; aparecen representaciones genéricas del tráfico (nPrint) y modelos multimodales (Distiller).	[24], [25], [26]
2022	ET-BERT populariza el preentrenamiento de Transformers sobre bytes. La deriva de datos y la calidad del etiquetado empiezan a verse como problemas centrales.	[12], [15], [29]
2023	CESNET publica TLS22 y QUIC22, capturados en una red en producción; aparecen TFE-GNN, YaTC y la librería DataZoo.	[3]–[7], [11], [16], [17], [28], [30]
2024	CESNET-TLS-Year22 ofrece un año completo de tráfico; NetMamba propone modelos de espacio de estados más eficientes.	[1], [2], [18], [27]
2025	Llega la autocritica: varios trabajos muestran que parte del desempeño casi perfecto se debía a fugas de información y a muestras repetidas, y que un modelo simple bien evaluado rinde igual que uno profundo.	[8]–[10], [13], [14], [20]–[23], [31]

Año	Qué cambió	Referencias
2026	Transformers sin preentrenamiento orientados a eficiencia; CESNET prepara un nuevo dataset QUIC de un año.	[19]

La tabla nro. 5 resume cómo se movió la investigación. El punto de quiebre es 2025: después de años de cifras cada vez más altas, la comunidad empezó a revisar cómo se estaban evaluando los modelos. Este proyecto se ubica justo en esa discusión.

2.2.5 Gap identificado y posicionamiento

Las soluciones actuales tienen tres limitaciones claras:

- **Evaluaciones optimistas.** Jerabek et al. [8] encontraron que la mayoría de los datasets tiene más de 50 % de muestras repetidas y que la partición aleatoria infla el desempeño frente a una partición por tiempo. Zhao et al. [13] y Wickramasinghe et al. [14] llegan a conclusiones parecidas.
- **Deriva temporal fuerte.** Sobre CESNET-TLS-Year22, un XGBoost promedia un F1 de 0,55 durante el año si no se reentrena, y de 0,86 si se reentrena cuando se detecta la deriva. El cambio más brusco ocurre en marzo de 2022 [10].
- **Costo ignorado.** Los trabajos con arquitecturas complejas casi siempre reportan exactitud y rara vez comparan, en igualdad de condiciones, cuánto cuesta entrenar y usar cada modelo frente a una línea base clásica.

En la literatura revisada encontré poca evidencia que compare, con el mismo protocolo, modelos clásicos, una red convolucional y un Transformer ligero sin preentrenamiento, usando solo metadatos, con partición temporal sobre un año de tráfico real y reportando juntos desempeño, costo y significancia estadística. Ese es el espacio que cubre este proyecto.

No propongo un modelo nuevo. El aporte es evidencia comparativa que cualquiera pueda reproducir. Sigo las recomendaciones más recientes [8], [9], [14]: partición por meses, exclusión de los campos que delatan la etiqueta y control de muestras duplicadas. Incluyo la solución simple como punto de referencia, de modo que el Transformer solo se recomienda si la supera con significancia estadística. Y entrego todo en una aplicación web ejecutable, algo poco común en un área donde los resultados suelen quedarse en tablas.

2.3 Análisis de datasets disponibles

2.3.1 Datasets evaluados

Evalué cuatro datasets públicos. Tres pertenecen a la familia CESNET, capturada en la red académica nacional de la República Checa y administrada con la librería cesnet-datazoo [7]. El cuarto es un clásico de laboratorio que sirve como punto de contraste.

Tabla 6

Ficha técnica de los cuatro datasets evaluados

Aspecto	CESNET-TLS-Year22	CESNET-TLS22	CESNET-QUIC22	ISCX VPN-nonVPN 2016
Fuente	Hynek et al. [1]; Zenodo, DOI 10.5281/zenodo.10608607 [2]	Luxemburk y Čejka [3]; Zenodo, DOI 10.5281/zenodo.7965515 [4]	Luxemburk et al. [5], [6]; Zenodo	Draper-Gil et al. [32]; Canadian Institute for Cybersecurity
Tamaño	507,7 M de flujos, 180 servicios en 24 categorías; submuestras XS (10 M), S, M y L	141,4 M de flujos; 191 servicios	153,2 M de flujos; 102 servicios	Decenas de GB en capturas PCAP
Periodo	Todo 2022	Dos semanas (octubre 2021)	Un mes (oct.–nov. 2022)	2016, laboratorio
Formato y estructura	CSV por semana y día; HDF5 en DataZoo. Secuencia de 30 paquetes, estadísticas de flujo, histogramas, campos TLS	Igual al anterior; misma API	Secuencias, estadísticas y campos QUIC; misma API	PCAP y CSV con características temporales
Licencia	CC BY 4.0 (verificada en Zenodo)	Acceso abierto; licencia por confirmar	Acceso abierto; licencia por confirmar	Uso libre en investigación, con cita
Calidad	Alta: validada por los autores; mismo exportador todo el año; tráfico real	Alta, pero periodo corto	Alta, solo QUIC	Media: inconsistencias de etiquetado reportadas [10]
Sesgos	Etiquetado por SNI; red académica checa; clases desbalanceadas; deriva artificial en marzo [10]	Mismos sesgos; no permite medir deriva larga	Cambio de certificados de Google en una semana [6], [8]	Tráfico de laboratorio, antiguo y con muchas muestras repetidas [8]
Acceso y costo	Público y gratuito; 30,5 GB completo	Público y gratuito	Público y gratuito	Gratuito, previa solicitud
Ventaja principal	Único con un año de tráfico real y publicación reciente	Reemplazo directo del principal	Cubre QUIC	Muy citado
Desventaja principal	Volumen alto; incluye campos que filtran la etiqueta	Sin deriva de largo plazo	Cambia el protocolo del problema	No cumple el criterio de actualidad; exige procesar PCAP

La tabla nro. 6 reúne la descripción técnica, la procedencia, la calidad, la idoneidad y la accesibilidad de cada dataset. La diferencia decisiva está en el periodo de captura: solo CESNET-TLS-Year22 permite entrenar con unos meses y probar con otros, que es la forma honesta de medir cómo envejece un modelo.

2.3.2 Comparación y recomendación

Tabla 7

Resumen comparativo de datasets

Dataset	Tamaño	Calidad	Licencia / costo	Acceso	Puntaje (1-5)
CESNET-TLS-Year22	507,7 M (XS: 10 M)	Alta, producción	CC BY 4.0 / gratis	Alto	5
CESNET-TLS22	141,4 M	Alta, 2 semanas	Abierta / gratis	Alto	4
CESNET-QUIC22	153,2 M	Alta, solo QUIC	Abierta / gratis	Alto	3
ISCX VPN-nonVPN	Decenas de GB	Media, laboratorio	Investigación / gratis	Medio	2

La tabla nro. 7 ordena los datasets por su utilidad para el proyecto. CESNET-TLS-Year22 es la elección principal porque combina tráfico real, publicación reciente, licencia abierta y un año completo. CESNET-TLS22 queda como plan B: comparte formato y API, así que el cambio se reduce a una línea de código. Si hubiera que usarlo, la evaluación temporal se limitaría a días consecutivos y lo declararía como limitación.

2.3.3 Plan de adquisición y preprocesamiento

- **Adquisición.** Instalar cesnet-datazoo y crear el dataset en tamaño XS (10 millones de flujos). La librería descarga sola la base de datos y el mapa de servicios.
- **Partición por meses.** Entrenar con septiembre de 2022, separando un 20 % para validación, y probar con octubre. Son los periodos que el propio dataset trae por defecto y quedan lejos de la deriva artificial de marzo [10]. Noviembre y diciembre sirven para medir cuánto se degrada cada modelo.
- **Etiquetas.** Pasar de servicio a categoría (24 clases) con el mapa oficial y descartar el tráfico de fondo.
- **Campos excluidos.** Quitar el SNI (se usó para etiquetar), la huella JA3, las direcciones IP, los puertos y el sistema autónomo de destino, porque delatan la etiqueta o identifican a los usuarios.
- **Duplicados.** Medir cuántas secuencias idénticas aparecen a la vez en entrenamiento y prueba, como recomienda [8].
- **Transformación.** Escalar las estadísticas para los modelos clásicos y convertir cada secuencia en un tensor de 30×3 (tamaño, dirección y tiempo) para las redes.

- **Muestras.** Exportar hasta 1 000 flujos por categoría del conjunto de prueba para la aplicación, la plantilla CSV y el repositorio, con la atribución que exige la licencia.

2.4 Definición de métricas de éxito

Según la Matriz de KPIs de la asignatura, el proyecto es de aprendizaje supervisado con clasificación multiclase. Para cada métrica fijé un mínimo aceptable y un objetivo de excelencia. Los umbrales de F1 no los inventé: salen del único estudio publicado que evaluó este dataset a lo largo del año [10], donde un modelo sin reentrenar promedia 0,55 y uno reentrenado llega a 0,86. Como aquí se entrena y se prueba en meses seguidos, el mínimo queda por encima del primer valor y la excelencia se alinea con el segundo.

2.4.1 Métricas técnicas

Tabla 8

Métricas técnicas y umbrales de éxito

Métrica	Qué mide y cómo se calcula	Mínimo	Excelencia	Referencia
F1 macro (principal)	Promedio simple del F1 de las 24 categorías; $F1 = \frac{2 \cdot P \cdot R}{P+R}$	$\geq 0,70$	$\geq 0,85$	0,55 sin reentrenar y 0,86 reentrenado [10]; adecuada con clases desbalanceadas
F1 ponderado	F1 promedio según el peso de cada clase	$\geq 0,80$	$\geq 0,90$	Refleja el volumen real de tráfico
Exactitud	$(VP + VN) / \text{total}$	Se reporta	Se reporta	Secundaria: engaña cuando hay desbalance
Precisión y recall por clase	$VP/(VP+FP)$ y $VP/(VP+FN)$ en cada categoría	Ningún recall $< 0,40$	Todos $\geq 0,60$	Detecta categorías que el modelo no aprende
Degradación temporal	F1 macro de octubre menos F1 macro de diciembre	Se reporta	≤ 10 puntos	La deriva es el problema central [10], [11]
Latencia	Milisegundos por flujo en CPU, en lotes de 1 024	≤ 10 ms	≤ 1 ms	La matriz de KPIs sugiere < 200 ms para APIs
Tamaño del modelo	Parámetros entrenables	Se reporta	Transformer ≤ 2 M	Debe correr en CPU
Tiempo de entrenamiento	Horas hasta converger	≤ 2 h en GPU gratuita	≤ 30 min	Viable sin pagar cómputo
Significancia	Prueba de McNemar sobre predicciones pareadas [36], [37]	Se ejecuta	$p < 0,05$	Solo así se declara que un modelo supera a otro

La tabla nro. 8 concentra las métricas del algoritmo. La regla de decisión es sencilla: si el mejor modelo profundo no supera al mejor modelo clásico con $p < 0,05$, recomendando el clásico por ser más barato. Ese resultado vale tanto como el contrario, porque también responde la pregunta de investigación.

2.4.2 Métricas de impacto, adopción y satisfacción

Tabla 9

Métricas de impacto, usabilidad y calidad de datos

Métrica	Qué mide y cómo	Mínimo	Excelencia	Cuándo
Cobertura sin descifrar	% de flujos clasificados usando solo metadatos	100 %	100 %	Por diseño
Ahorro de cómputo	Latencia y tiempo de entrenamiento del modelo recomendado frente al más costoso	Se reporta	≥ 50 % menos sin perder F1 significativo	Sprint 3
Usabilidad (SUS)	Escala SUS [38] aplicada a evaluadores después de usar la aplicación	≥ 68	≥ 80	Sprint 3
Éxito de tareas	% de evaluadores que exploran datos, comparan modelos y clasifican un flujo sin ayuda	≥ 80 %	100 %	Sprint 3
Tiempo a la primera clasificación	Segundos desde que abren la aplicación hasta ver una predicción	≤ 120 s	≤ 60 s	Sprint 3
Satisfacción	Pregunta de 1 a 5: «La aplicación me ayudó a entender los resultados»	≥ 4	≥ 4,5	Sprint 3
Errores de la aplicación	% de acciones que terminan en error	< 1 %	0 %	Continuo
Calidad de datos	% de campos completos y que cumplen el esquema	≥ 95 %	100 %	Sprint 1

La tabla nro. 9 cubre lo que no es estrictamente técnico. Un prototipo académico no tiene clientes, así que calcular un ROI sería inventar números. En su lugar medí lo que sí se puede verificar en seis semanas: cuánto cómputo se ahorra, si al menos cinco personas logran usar la aplicación sin ayuda y qué tan satisfechas quedan.

2.4.3 KPIs seleccionados y seguimiento

Tabla 10

KPIs seleccionados según la plantilla de la matriz

Tipo	KPI	Meta	Línea base	Frecuencia
Principal	F1 macro en octubre de 2022	≥ 0,70 (excelencia 0,85)	Random Forest, sprint 1	Cada experimento
Técnico	Latencia por flujo	≤ 10 ms en CPU	Random Forest	Por modelo
Impacto	Ahorro de cómputo del modelo recomendado	≥ 50 %	Modelo más costoso	Sprint 3
Calidad	Compleitud y esquema	≥ 95 %	Datos XS sin procesar	Sprint 1
Adopción	SUS y éxito de tareas	SUS ≥ 68; éxito ≥ 80 %	Sin versión previa	Sprint 3

La tabla nro. 10 reduce todo a cinco indicadores que se revisan de forma periódica. Cada experimento guarda sus resultados en el repositorio, y la página «Arena de modelos» de la aplicación hace de tablero: muestra el KPI principal, la evolución del F1 mes a mes y una alerta cuando un modelo no alcanza el mínimo.

2.5 Análisis de stakeholders

Identifiqué doce actores entre primarios, secundarios y clave. La influencia y el interés se califican como Alto (A), Medio (M) o Bajo (B).

Tabla 11

Identificación de stakeholders

Stakeholder	Categoría	Inf.	Int.	Necesidades	Posibles resistencias	Cómo involucrarlo
Docente del Proyecto Integrador	Clave	A	A	Objetivos SMART, rigor, avances puntuales	Desacuerdo con el alcance	Revisión al cierre de cada sprint
Tribunal evaluador	Primario	A	M	Resultados claros y una demostración que funcione	Escepticismo si no hay significancia	App autoexplicativa; McNemar en lenguaje llano
Autor (Product Owner, Scrum Master y desarrollador)	Clave	A	A	Terminar a tiempo y con calidad	Sobrecarga	Backlog priorizado; LSTM fuera del compromiso
Administradores de red de proveedores y empresas	Primario	B	A	Saber qué modelo usar y cuánto cuesta	Desconfianza en modelos de caja negra	Conclusiones pensadas para la operación
Equipos de seguridad (SOC)	Primario	B	A	Ver el tráfico sin descifrarlo	Preferencia por herramientas comerciales	Destacar privacidad y latencia
Evaluadores de usabilidad	Primario	B	M	Una aplicación clara y rápida	Poco tiempo disponible	Prueba corta y agendada con antelación
CESNET (proveedor de datos)	Secundario	A	B	Atribución correcta según CC BY 4.0	Ninguna si se cumple la licencia	Citar dataset y paper en app y repositorio
Colab, Kaggle, Hugging Face, GitHub	Secundario	M	B	Uso dentro de sus condiciones	Límites de sesión o caídas	Plan B local y respaldos por época
ARCOTEL y Superintendencia de Protección de Datos Personales	Secundario	M	B	Que no se traten datos personales	Dudas sobre privacidad	Declarar que se excluyen IP y dominios
Soluciones comerciales y librerías DPI (nDPI)	Secundario	B	B	—	Alternativas maduras	Presentar el proyecto como evidencia, no como producto
Comunidad académica	Secundario	B	M	Resultados reproducibles	Críticas de método	Repositorio público con semillas y particiones
Especialistas en redes y seguridad	Clave	M	M	Coherencia técnica	Poca disponibilidad	Consulta puntual en el sprint 1

La tabla nro. 11 describe a cada actor, lo que espera del proyecto, lo que podría frenarlo y la manera de mantenerlo involucrado. Incluí a los reguladores ecuatorianos aunque su interés sea bajo, porque cualquier trabajo con tráfico de red despierta preguntas legítimas sobre privacidad.

Tabla 12
Matriz de influencia e interés (A se ubica como alta; M y B como baja)

	Interés bajo	Interés alto
Influencia alta	Mantener satisfecho: CESNET, tribunal evaluador	Gestionar de cerca: docente, autor
Influencia baja	Monitorear: plataformas tecnológicas, reguladores, competidores indirectos	Mantener informado: administradores de red, equipos SOC, evaluadores, comunidad académica, especialistas

La tabla nro. 12 ubica a cada stakeholder en su cuadrante. La consecuencia práctica es que el esfuerzo de comunicación se concentra en el docente, mientras que con CESNET basta con cumplir bien la licencia.

Tabla 13
Plan de comunicación diferenciado

Stakeholder	Canal	Frecuencia	Mensaje clave
Docente	Blackboard y reunión virtual	Cierre de cada sprint	Avance frente al objetivo del sprint, riesgos y decisiones
Tribunal evaluador	Documento, aplicación y sustentación	Entrega final	Qué modelo conviene, por qué y a qué costo
Evaluadores	Mensajería y formulario en línea	Invitación en semana 4, prueba en semana 5	Instrucciones y agradecimiento
Administradores de red y SOC	README y página de conclusiones	Versión final	Modelo recomendado y latencia esperada
CESNET y comunidad	Repositorio GitHub con citas	Permanente	Uso del dataset conforme a CC BY 4.0
Reguladores	Nota de privacidad en documento y app	Única	Solo metadatos; sin contenido ni datos personales

La tabla nro. 13 define por dónde, cada cuánto y con qué mensaje se comunica el proyecto a cada grupo.

2.6 Documento de alcance del proyecto

2.6.1 Objetivo general

- Desarrollar, en seis semanas, un estudio comparativo entre modelos clásicos de aprendizaje automático y arquitecturas profundas basadas en atención para clasificar tráfico de red cifrado en 24 categorías de servicio sobre el dataset CESNET-TLS-Year22, evaluando desempeño (F1 macro) y costo computacional con partición temporal, y poniendo los resultados a disposición en una aplicación web interactiva.

2.6.2 Objetivos específicos

Tabla 14

Objetivos específicos y su relación con las métricas

OE	Enunciado	Métricas asociadas	Sprint
OE1	Construir el conjunto experimental a partir de CESNET-TLS-Year22 mediante la muestra XS, la partición por meses (septiembre para entrenar, octubre para probar, noviembre y diciembre para la deriva), la exclusión de campos que filtran la etiqueta y el análisis exploratorio de las 24 categorías, para que todos los modelos trabajen en condiciones idénticas y reproducibles.	Calidad $\geq 95\%$; duplicados reportados; F1 macro de la línea base	1
OE2	Evaluar comparativamente el desempeño y el costo computacional de Random Forest, XGBoost, una red convolucional 1D y un Transformer encoder ligero mediante F1 macro y ponderado, exactitud, matriz de confusión, latencia, parámetros, tiempo de entrenamiento y la prueba de McNemar ($\alpha = 0,05$), para determinar qué familia de modelos ofrece el mejor equilibrio.	F1 macro $\geq 0,70$; latencia ≤ 10 ms; McNemar; degradación	2 y 3
OE3	Desarrollar y desplegar una aplicación web en Streamlit que integre la exploración del dataset, la comparación de modelos y la clasificación de flujos en tiempo real, y validar su usabilidad con al menos cinco evaluadores mediante la escala SUS, para que los resultados puedan demostrarse y ejecutarse.	SUS ≥ 68 ; éxito $\geq 80\%$; errores $< 1\%$	3 y 4

La tabla nro. 14 presenta los tres objetivos específicos. Cada uno tiene una métrica que permite decir, sin ambigüedad, si se cumplió o no, y juntos suman exactamente lo que promete el objetivo general.

2.6.3 Alcance incluido

- **Funcionalidades:** pipeline reproducible de carga y partición; cuatro modelos con las mismas particiones y semillas; módulo común de métricas; prueba de McNemar; aplicación web con cinco páginas (Inicio, Explorador de datos, Arena de modelos, Clasificador en vivo y Conclusiones); carga de CSV con plantilla; despliegue en Docker con URL pública.
- **Datos:** metadatos de flujos TLS, es decir, secuencias de los primeros 30 paquetes, estadísticas de flujo e histogramas, etiquetados en 24 categorías.
- **Usuarios y casos de uso:** un administrador de red que compara modelos antes de decidir cuál desplegar; un evaluador académico que revisa y reproduce los resultados; cualquier usuario que quiera clasificar flujos de prueba o un CSV propio.

2.6.4 Alcance excluido

- **Fuera del proyecto:** procesar archivos PCAP, capturar tráfico propio, integrarse con colectores NetFlow/IPFIX, reentrenar automáticamente en producción y detectar intrusiones.
- **Limitaciones conocidas:** sin el contenido de los paquetes no se pueden reproducir ET-BERT, YaTC ni TFE-GNN; los resultados vienen de una red académica checa y no se trasladan de forma automática a otras redes; las 180 etiquetas finas no se clasifican.
- **Para versiones futuras:** un modelo LSTM (opcional si sobra tiempo en el sprint 3), la opción de rechazar clases desconocidas, la detección automática de deriva y la validación con tráfico ecuatoriano.

2.6.5 Criterios de aceptación

Tabla 15

Criterios de aceptación de los entregables

Entregable	Se considera terminado cuando...	Cómo se valida
Conjunto experimental (OE1)	Las particiones existen con los periodos definidos, los campos con fuga están fuera, la calidad es $\geq 95\%$ y el EDA muestra las 24 categorías y la deriva mensual	El notebook corre de principio a fin sin errores en un entorno limpio
Estudio comparativo (OE2)	Los cuatro modelos se evaluaron con las mismas particiones, la tabla de métricas está completa, McNemar se ejecutó y al menos un modelo llega a $F1 \text{ macro} \geq 0,70$	Script reproducible con semilla fija y resultados versionados
Aplicación web (OE3)	Las cinco páginas funcionan en la URL pública, la clasificación tarda ≤ 10 ms por flujo y la prueba SUS da ≥ 68 con al menos cinco evaluadores	Checklist funcional y reporte de la prueba de usabilidad
Repositorio	README completo, dependencias con versión fija, licencias, citas y muestras del dataset	Un tercero lo clona y lo ejecuta siguiendo el README
Informe final	Resultados, discusión, limitaciones y referencias IEEE	Revisión del docente

La tabla nro. 15 fija las condiciones para dar por terminado cada entregable. Como estándar mínimo de calidad, ninguna métrica se reporta sin el script que la genera y todas las funciones del pipeline tienen pruebas unitarias.

2.6.6 Supuestos y restricciones

Tabla 16

Supuestos y restricciones

Supuestos	Restricciones
La librería cesnet-datazoo y su servidor de descarga siguen disponibles	Plazo fijo de seis semanas (28/09 al 08/11/2026)
La muestra XS tiene suficientes ejemplos de las 24 categorías en los meses elegidos	Proyecto individual, con 15 horas semanales de dedicación

Supuestos	Restricciones
Colab o Kaggle ofrecen GPU gratuita suficiente para modelos pequeños	Solo recursos gratuitos o de muy bajo costo
Al menos cinco evaluadores pueden participar en la semana 5	Solo metadatos; nunca el contenido de los paquetes
El docente valida el alcance al cierre del sprint 1	Cumplir la licencia CC BY 4.0 del dataset

La tabla nro. 16 hace explícito aquello de lo que depende el proyecto. Si alguno de los supuestos falla, la respuesta está prevista en la matriz de riesgos del cronograma.

2.7 Cronograma con metodología ágil (Scrum)

2.7.1 Ceremonias y artefactos

Tabla 17

Adaptación de Scrum a un proyecto individual

Elemento	Cómo se aplica
Sprint Planning	Al inicio de cada sprint, una hora para definir el objetivo, elegir historias y estimarlas en puntos (escala Fibonacci)
Daily Scrum	Registro diario de diez minutos en el tablero: qué hice, qué haré y qué me está frenando
Sprint Review	Al cierre de cada sprint, entre 30 y 45 minutos con el docente para mostrar el incremento
Retrospectiva	Treinta minutos al cierre de cada sprint con el formato empezar, dejar y continuar
Refinamiento	Treinta minutos por semana para revisar y reestimar el backlog
Artefactos	Product Backlog y Sprint Backlog en GitHub Projects; cada historia es un issue; el incremento vive en la rama main

La tabla nro. 17 resume cómo se ajustan las ceremonias cuando el equipo es una sola persona. La Definition of Done general es la misma para todas las historias: el código entra a main por pull request, pasa las pruebas unitarias, corre con semilla fija, deja sus métricas registradas y queda documentado.

2.7.2 Product Backlog priorizado

Tabla 18

Product Backlog con historias de usuario, prioridad MoSCoW y story points

ID	Historia de usuario	Prioridad	SP	Sprint	OE
US-01	Como investigador, quiero un entorno reproducible (venv, requirements y repositorio) para que cualquiera ejecute el proyecto.	Must	3	1	OE1
US-02	Como investigador, quiero descargar y cargar la muestra XS con DataZoo para disponer de los datos.	Must	5	1	OE1
US-03	Como investigador, quiero definir las particiones por mes y excluir los campos con fuga para no inflar los resultados.	Must	3	1	OE1
US-04	Como analista, quiero un EDA de las 24 categorías y de la deriva mensual para entender los datos.	Must	5	1	OE1
US-05	Como investigador, quiero una línea base con Random Forest y sus métricas para tener contra qué comparar.	Must	5	1	OE2

ID	Historia de usuario	Prioridad	SP	Sprint	OE
US-06	Como investigador, quiero un módulo común de métricas para medir a todos los modelos de la misma forma.	Must	5	2	OE2
US-07	Como investigador, quiero entrenar y evaluar XGBoost con las mismas particiones.	Must	3	2	OE2
US-08	Como investigador, quiero convertir las secuencias de paquetes en tensores para las redes profundas.	Must	5	2	OE2
US-09	Como investigador, quiero entrenar y evaluar una red convolucional 1D.	Must	8	2	OE2
US-10	Como investigador, quiero entrenar y evaluar un Transformer encoder ligero.	Must	8	2	OE2
US-11	Como desarrollador, quiero pruebas unitarias y de integración del pipeline.	Must	3	2	OE2
US-12	Como investigador, quiero ajustar hiperparámetros para comparar cada modelo en su mejor versión.	Should	5	3	OE2
US-13	Como analista, quiero la tabla comparativa final y la prueba de McNemar para decidir qué recomendar.	Must	3	3	OE2
US-14	Como usuario, quiero las páginas Inicio y Explorador de datos para entender el problema y los datos.	Must	5	3	OE3
US-15	Como administrador de red, quiero la página Arena de modelos para comparar desempeño y costo.	Must	5	3	OE3
US-16	Como usuario, quiero clasificar flujos reales o mi propio CSV en tiempo real.	Must	8	3	OE3
US-17	Como evaluador, quiero la aplicación publicada con URL para usarla sin instalar nada.	Must	3	3	OE3
US-18	Como autor, quiero una prueba SUS con cinco evaluadores para validar la aplicación.	Must	3	3	OE3
US-19	Como desarrollador, quiero pruebas integrales y corrección de defectos.	Must	3	4	OE3
US-20	Como evaluador, quiero documentación técnica y de usuario para entender y reproducir el proyecto.	Must	5	4	OE3
US-21	Como autor, quiero la presentación final y un video de respaldo de la demostración.	Must	3	4	OE3
US-22	Como investigador, quiero un modelo LSTM como comparación adicional.	Could	5	3–4	OE2

La tabla nro. 18 ordena el trabajo en 22 historias. La capacidad planificada es de 21 puntos en el sprint 1 (una semana), 32 en el sprint 2 (dos semanas), 32 en el sprint 3 (dos semanas) y 11 en el sprint 4 (una semana). La historia US-22 es la única marcada como Could y no forma parte del compromiso.

2.7.3 Planificación de sprints

Tabla 19

Objetivo, historias, Definition of Done y riesgos de cada sprint

Sprint	Sprint Goal	Historias (SP)	Definition of Done específica	Riesgos y mitigación
1. Investigación y diseño 28/09 – 04/10	Entorno listo, muestra XS cargada, particiones definidas, EDA y línea base Random Forest medida	US-01 a US-05 (21)	EDA ejecutable de inicio a fin; calidad $\geq 95\%$; F1 de Random Forest registrado	Descarga lenta (Zenodo ha tenido intermitencias): iniciarla el primer día; plan B con CESNET-TLS22

Sprint	Sprint Goal	Historias (SP)	Definition of Done específica	Riesgos y mitigación
2. Desarrollo core 05/10 – 18/10	Cuatro modelos entrenados con las mismas particiones y métricas registradas	US-06 a US-11 (32)	Cada modelo con script reproducible, métricas guardadas y pruebas aprobadas	Si el Transformer no converge: menos capas y otra tasa de aprendizaje; en último caso se reporta con sus límites. Límites de Colab: respaldos por época y Kaggle
3. Optimización, validación e interfaz 19/10 – 01/11	Comparativa final con McNemar, app publicada y prueba SUS realizada	US-12 a US-18 (32); US-22 si hay holgura	Tabla final versionada; cinco páginas en la URL pública; resultados SUS documentados	Si falla el despliegue: demo local con Docker. Si faltan evaluadores: agendar en semana 4 y permitir modalidad remota
4. Cierre y documentación 02/11 – 08/11	Sistema probado, documentación completa y presentación ensayada	US-19 a US-21 (11)	Checklist de pruebas aprobado; README e informe completos; video grabado	Defectos de última hora: congelar funcionalidades al inicio del sprint

La tabla nro. 19 resume los cuatro sprints. Siguen el orden que pide la asignatura: investigación y diseño, desarrollo del núcleo, optimización con la interfaz de usuario y, por último, pruebas integrales y documentación.

Tabla 20

Cronograma por semanas (■ = actividad planificada)

Actividad	S1 28/09	S2 05/10	S3 12/10	S4 19/10	S5 26/10	S6 02/11
Entorno, datos, particiones y EDA	■					
Línea base Random Forest	■					
XGBoost y módulo de métricas		■				
Red convolucional 1D		■	■			
Transformer ligero		■	■			
Ajuste de hiperparámetros y McNemar				■		
Aplicación web				■	■	
Despliegue y prueba SUS					■	
Pruebas integrales y documentación						■
Presentación final						■
Sprint	1	2	2	3	3	4

La tabla nro. 20 distribuye las actividades en las seis semanas. La plantilla de la asignatura sugiere dedicar entre 40 y 50 % del tiempo a los datos; aquí esa fase ocupa cerca de 20 % porque el dataset llega limpio, etiquetado y con librería oficial, un ajuste que la misma plantilla contempla. El modelado toma alrededor de la mitad del tiempo y el despliegue con la documentación, el resto.

2.7.4 Matriz de riesgos

Tabla 21

Matriz de riesgos del proyecto (nivel = probabilidad × impacto)

#	Riesgo	Probabilidad	Impacto	Nivel	Mitigación
1	Descarga fallida o lenta del dataset	Media (2)	Alto (3)	6 – Medio	Descargar el primer día; plan B con CESNET-TLS22
2	El Transformer no converge a tiempo	Media (2)	Medio (2)	4 – Medio	Reducir el modelo; si persiste, reportarlo y seguir con tres modelos
3	Límites de sesión de la GPU gratuita	Media (2)	Medio (2)	4 – Medio	Modelos pequeños, respaldos por época, Kaggle como alternativa
4	Ningún modelo alcanza F1 macro 0,70	Baja (1)	Alto (3)	3 – Bajo	Analizar las categorías con peor desempeño y documentar el hallazgo
5	Falla del despliegue en la nube	Baja (1)	Medio (2)	2 – Bajo	Demo local con Docker y video de respaldo
6	Pocos evaluadores para la prueba SUS	Media (2)	Bajo (1)	2 – Bajo	Invitar con una semana de anticipación; modalidad remota
7	Sobrecarga del autor	Media (2)	Medio (2)	4 – Medio	Respetar el backlog; LSTM fuera del compromiso

La tabla nro. 21 recoge los riesgos con su nivel y su respuesta. Los más serios son la descarga del dataset y la convergencia del Transformer; por eso el primero se ataca el día uno y el segundo tiene una salida prevista que no hunde el proyecto.

2.8 Plan de recursos

2.8.1 Recursos humanos

Tabla 22

Horas estimadas por rol y sprint

Rol	S1	S2	S3	S4	Total	%
Gestión: planificación, backlog, reviews	2	3	3	2	10	11 %
Análisis de datos: EDA, métricas, evaluación	8	8	6	2	24	27 %
Ingeniería de ML: modelos y pipeline	4	17	6	0	27	30 %
Desarrollo de la aplicación y despliegue	0	0	13	2	15	17 %
Documentación y presentación	1	2	2	9	14	15 %
Total del autor	15	30	30	15	90	100 %
Docente (Sprint Reviews)	1	1	1	1	4	—
Evaluadores de usabilidad (5 × 0,5 h)	0	0	2,5	0	2,5	—

La tabla nro. 22 reparte las 90 horas del proyecto, a razón de 15 por semana. El mayor esfuerzo cae en el sprint 2, cuando se entrenan los cuatro modelos.

2.8.2 Recursos técnicos

Tabla 23

Recursos técnicos requeridos

Categoría	Recurso	Disponibilidad
Hardware	Laptop propia con 16 GB de RAM y al menos 40 GB libres	Disponible
GPU	Google Colab o Kaggle Notebooks (nivel gratuito)	Disponible, con límites de sesión
Software	VS Code, Python 3.11, cesnet-datazoo, pandas, scikit-learn, XGBoost, PyTorch, statsmodels, Streamlit y Docker, todos de código abierto	Disponible, sin licencias
Plataformas	Hugging Face Spaces para publicar la app; GitHub para código, tablero y resultados	Disponible
Datos	CESNET-TLS-Year22 bajo CC BY 4.0	Disponible, sin costo

La tabla nro. 23 confirma que todo lo necesario ya existe o es gratuito, lo que reduce el riesgo de depender de una compra.

2.8.3 Recursos financieros

Tabla 24

Presupuesto estimado por categorías (USD)

Categoría	Base de cálculo	Valorizado	Desembolso	%
Personal: autor	90 h × USD 15/h (tarifa referencial)	1 350,00	0,00	81,4 %
Personal: docente y evaluadores	Dentro de la asignatura / voluntarios	0,00	0,00	0,0 %
Laptop propia	Depreciación: USD 1 000 / 36 meses × 1,5 meses	41,67	0,00	2,5 %
GPU de pago (opcional)	Dos meses de suscripción, estimado	20,00	20,00	1,2 %
Internet y energía	Parte proporcional a 90 horas	30,00	30,00	1,8 %
Software y datos	Código abierto y dataset CC BY 4.0	0,00	0,00	0,0 %
Subtotal		1 441,67	50,00	86,9 %
Contingencia (15 %)	15 % del subtotal	216,25	7,50	13,1 %
Total		1 657,92	57,50	100 %

La tabla nro. 24 separa lo que el proyecto vale de lo que realmente se paga. La tarifa horaria es un valor de referencia que asumí para poder valorizar el trabajo, y el precio de la GPU se confirmará antes de contratarla. La contingencia cubriría, por ejemplo, un disco externo o más horas de GPU si el Transformer lo exige.

La gestión de estos recursos es simple: el dataset se descarga una sola vez el primer día; la GPU gratuita se usa en el sprint 2 con sesiones programadas; la GPU de pago solo se contrata si en la semana 3 las sesiones gratuitas no alcanzan, y esa decisión queda registrada en el tablero; Hugging Face Spaces se

configura en la semana 4; y a los evaluadores se les invita en la semana 4 para la prueba de la semana 5.

2.9 Hitos y entregables

Definí ocho hitos repartidos en las seis semanas. En todos el responsable de la entrega es el autor y la aprobación formal ocurre en la Sprint Review con el docente.

Tabla 25

Hitos del proyecto, entregables y criterios de aceptación

Hito	Fecha	Entregable y formato	Criterios de aceptación	Riesgo y contingencia
H1	30/09	Repositorio inicializado, requirements.txt con versiones fijas y muestra XS descargada	El entorno se crea desde cero con el README en menos de 30 minutos; la librería reporta 10 000 000 de flujos	Descarga fallida: reintento y plan B con CESNET-TLS22
H2	04/10	Notebook de EDA (.ipynb y HTML), reporte de calidad y resultados de Random Forest (JSON)	Particiones creadas; campos con fuga excluidos; calidad ≥ 95 %; F1 de la línea base registrado	Categorías con muy pocos datos: agruparlas o excluirlas con justificación
H3	11/10	Scripts de Random Forest y XGBoost, módulo de métricas con pruebas y tabla parcial	Ambos modelos evaluados con las mismas particiones; latencia y tiempo medidos; pruebas aprobadas	Memoria insuficiente: submuestreo estratificado
H4	18/10	Scripts de la red 1D y del Transformer, pesos (.pt) y curvas de entrenamiento	Ambos convergen; métricas registradas; Transformer con ≤ 2 M de parámetros	Sin convergencia: se reporta y se sigue con tres modelos
H5	25/10	Tabla comparativa final (CSV y figura), McNemar y análisis de deriva	Métricas completas de los cuatro modelos; al menos uno con $F1 \geq 0,70$; recomendación justificada	Ningún modelo llega a 0,70: análisis por categoría y hallazgo documentado
H6	01/11	Aplicación publicada, imagen Docker y reporte SUS	Cinco páginas operativas; ≤ 10 ms por flujo; SUS ≥ 68 con cinco evaluadores; éxito ≥ 80 %	Falla en la nube: demo local y video
H7	06/11	Informe técnico en PDF, README, guía de uso y repositorio etiquetado v1.0	Un tercero ejecuta el proyecto siguiendo el README; referencias IEEE completas	Retraso en la redacción: plantilla del informe lista desde el sprint 1
H8	08/11	Presentación final, video de respaldo y retrospectiva	Presentación ensayada dentro del tiempo; aplicación accesible en la sustentación	Problemas de conexión: video y app local

La tabla nro. 25 detalla los ocho hitos con su entregable, cómo se sabe que está cumplido y qué hacer si algo sale mal. Las fechas críticas son el 4 de octubre, porque sin línea base no hay comparación; el 18 de octubre, porque de los modelos profundos depende la comparativa; y el 1 de noviembre, porque la aplicación es lo que se demuestra.

Cada hito sigue el mismo recorrido: primero reviso los criterios de aceptación, luego dejo la evidencia en GitHub Projects, después se revisa en la Sprint Review y, si hay observaciones, se convierten en historias correctivas para el sprint siguiente.

Conclusiones

- La revisión del estado del arte dejó claro que el problema de fondo ya no es alcanzar una exactitud alta, sino medirla bien. Por eso el proyecto apuesta por una partición por meses, por excluir los campos que delatan la etiqueta y por comparar siempre contra una línea base simple.
- CESNET-TLS-Year22 es el único de los datasets evaluados que permite estudiar cómo envejece un modelo con tráfico real, y su licencia CC BY 4.0 facilita publicar muestras y resultados. CESNET-TLS22 queda como respaldo inmediato si hubiera problemas de acceso.
- Los umbrales de éxito se apoyan en un benchmark publicado sobre el mismo dataset y no en cifras supuestas. Además, la regla de decisión con McNemar evita recomendar un modelo costoso cuando la mejora no es estadísticamente significativa.
- La planificación en cuatro sprints concentra el mayor riesgo técnico en las semanas 2 y 3 y deja salidas previstas para cada caso. Si el Transformer no converge, la comparación sigue siendo válida con los otros tres modelos.
- La aplicación web y la prueba de usabilidad convierten un estudio que normalmente se quedaría en tablas en algo que el tribunal puede usar y verificar por sí mismo.

Referencias bibliográficas

- [1] K. Hynek, J. Luxemburk, J. Pešek, T. Čejka y P. Šiška, "CESNET-TLS-Year22: A year-spanning TLS network traffic dataset from backbone lines," *Sci. Data*, vol. 11, 2024, doi: 10.1038/s41597-024-03927-4.
- [2] K. Hynek, J. Luxemburk, J. Pešek, T. Čejka y P. Šiška, "CESNET-TLS-Year22," Zenodo, 2024, doi: 10.5281/zenodo.10608607.
- [3] J. Luxemburk y T. Čejka, "Fine-grained TLS services classification with reject option," *Comput. Netw.*, vol. 220, art. 109467, 2023, doi: 10.1016/j.comnet.2022.109467.
- [4] J. Luxemburk y T. Čejka, "CESNET-TLS22: A large dataset for fine-grained classification of TLS services," Zenodo, 2023, doi: 10.5281/zenodo.7965515.
- [5] J. Luxemburk, K. Hynek, T. Čejka, A. Lukačovič y P. Šiška, "CESNET-QUIC22: A large one-month QUIC network traffic dataset from backbone lines," *Data Brief*, vol. 46, art. 108888, 2023, doi: 10.1016/j.dib.2023.108888.
- [6] J. Luxemburk, K. Hynek y T. Čejka, "Encrypted traffic classification: The QUIC case," en *Proc. 7th Netw. Traffic Meas. Anal. Conf. (TMA)*, 2023, pp. 1–10, doi: 10.23919/TMA58422.2023.10199052.
- [7] J. Luxemburk y K. Hynek, "DataZoo: Streamlining traffic classification experiments," en *Proc. 2023 Workshop Explainable Safety Bounded Fidelity Mach. Learn. Netw. (SAFE)*, 2023, pp. 3–7.
- [8] K. Jerabek, J. Luxemburk, R. Plný, J. Koumar, J. Pešek y K. Hynek, "When simple model just works: Is network traffic classification in crisis?," *arXiv:2506.08655*, 2025.
- [9] J. Pešek, J. Luxemburk y K. Hynek, "Lightweight traffic classification: A simple baseline matching deep learning performance," en *Proc. 9th Netw. Traffic Meas. Anal. Conf. (TMA)*, 2025, pp. 1–4.
- [10] D. Soukup, R. Plný, D. Vašata y T. Čejka, "Drift-based dataset stability benchmark," *arXiv:2512.23762*, 2025.
- [11] N. Malekghaini et al., "Deep learning for encrypted traffic classification in the face of data drift: An empirical study," *Comput. Netw.*, vol. 225, art. 109648, 2023, doi: 10.1016/j.comnet.2023.109648.
- [12] N. Malekghaini et al., "Data drift in DL: Lessons learned from encrypted traffic classification," en *Proc. IFIP Netw. Conf.*, 2022, pp. 1–9.
- [13] Y. Zhao, G. Dettori, M. Boffa, L. Vassio y M. Mellia, "The sweet danger of sugar: Debunking representation learning for encrypted traffic classification," en *Proc. ACM SIGCOMM*, 2025, pp. 296–310.
- [14] N. Wickramasinghe et al., "SoK: Decoding the enigma of encrypted network traffic classifiers," en *Proc. IEEE Symp. Secur. Privacy (S&P)*, 2025.
- [15] X. Lin, G. Xiong, G. Gou, Z. Li, J. Shi y J. Yu, "ET-BERT: A contextualized datagram representation with pre-training transformers for encrypted traffic classification," en *Proc. ACM Web Conf. (WWW)*, 2022, pp. 633–642, doi: 10.1145/3485447.3512217.

- [16] R. Zhao et al., "Yet another traffic classifier: A masked autoencoder based traffic transformer with multi-level flow representation," en Proc. AAAI Conf. Artif. Intell., 2023.
- [17] H. Zhang et al., "TFE-GNN: A temporal fusion encoder using graph neural networks for fine-grained encrypted traffic classification," en Proc. ACM Web Conf. (WWW), 2023, pp. 2066–2075, doi: 10.1145/3543507.3583227.
- [18] T. Wang, X. Xie, W. Wang, C. Wang, Y. Zhao y Y. Cui, "NetMamba: Efficient network traffic classification via pre-training unidirectional Mamba," en Proc. IEEE 32nd Int. Conf. Netw. Protocols (ICNP), 2024, pp. 1–11, doi: 10.1109/ICNP61940.2024.10858569.
- [19] Z. Yan, L. Peng, P. Liu, Y. Bao y B. Yang, "NT-Transformer: A non-pretrained encrypted network traffic classification model," IEEE Trans. Netw. Serv. Manag., 2026, doi: 10.1109/TNSM.2026.3683410.
- [20] L. Yang et al., "MM4flow: A pre-trained multi-modal model for versatile network traffic analysis," en Proc. ACM SIGSAC Conf. Comput. Commun. Secur. (CCS), 2025, pp. 1664–1678.
- [21] S. Cui et al., "FG-SAT: Efficient flow graph for encrypted traffic classification under environment shifts," IEEE Trans. Inf. Forensics Security, 2025.
- [22] X. Lin et al., "Respond to change with constancy: Instruction-tuning with LLM for non-IID network traffic classification," IEEE Trans. Inf. Forensics Security, 2025.
- [23] Y. Chen, B. Hou, B. Wu y H. Hu, "CD-Net: Robust mobile traffic classification against apps updating," Comput. Secur., vol. 150, art. 104214, 2025.
- [24] G. Aceto et al., "Distiller: Encrypted traffic classification via multimodal multitask deep learning," J. Netw. Comput. Appl., vol. 183, art. 102985, 2021.
- [25] I. Akbari et al., "A look behind the curtain: Traffic classification in an increasingly encrypted web," Proc. ACM Meas. Anal. Comput. Syst., vol. 5, no. 1, pp. 1–26, 2021.
- [26] J. Holland, P. Schmitt, N. Feamster y P. Mittal, "New directions in automated traffic analysis," en Proc. ACM SIGSAC Conf. Comput. Commun. Secur. (CCS), 2021, pp. 3366–3383.
- [27] J. Koumar et al., "NetTiSA: Extended IP flow with time-series features for universal bandwidth-constrained high-speed network traffic classification," Comput. Netw., art. 110147, 2024.
- [28] S. Almuhammadi, A. Alnajam y M. Ayub, "QUIC network traffic classification using ensemble machine learning techniques," Appl. Sci., vol. 13, no. 8, art. 4725, 2023, doi: 10.3390/app13084725.
- [29] J. L. Guerra, C. Catania y E. Veas, "Datasets are not enough: Challenges in labeling network traffic," Comput. Secur., vol. 120, art. 102810, 2022.
- [30] J. Pešek, D. Soukup y T. Čejka, "Active learning framework for long-term network traffic classification," en Proc. IEEE 13th Annu. Comput. Commun. Workshop Conf. (CCWC), 2023, pp. 893–899.

- [31] A. Guerra-Manzanares, M. Caprolu y R. Di Pietro, "A comprehensive review on machine learning-based VPN detection," *Comput. Sci. Rev.*, vol. 58, art. 100781, 2025, doi: 10.1016/j.cosrev.2025.100781.
- [32] G. Draper-Gil, A. H. Lashkari, M. S. I. Mamun y A. A. Ghorbani, "Characterization of encrypted and VPN traffic using time-related features," en *Proc. 2nd Int. Conf. Inf. Syst. Secur. Privacy (ICISSP)*, 2016, pp. 407–414.
- [33] A. Vaswani et al., "Attention is all you need," en *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [34] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.
- [35] T. Chen y C. Guestrin, "XGBoost: A scalable tree boosting system," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794.
- [36] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
- [37] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Comput.*, vol. 10, no. 7, pp. 1895–1923, 1998.
- [38] J. Brooke, "SUS: A quick and dirty usability scale," en *Usability Evaluation in Industry*, P. W. Jordan et al., Eds. Londres: Taylor & Francis, 1996, pp. 189–194.
- [39] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [40] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library," en *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 32, 2019.

ANEXOS

Anexo A

Repositorio del proyecto en GitHub: _____
(agregar la URL una vez publicado).

Estructura inicial del repositorio:

```
cesnet-tls-classification/
├── README.md           descripción, instalación, uso, licencias y citas
├── LICENSE             MIT (código); datos CC BY 4.0 (CESNET)
├── requirements.txt    versiones fijas
├── Dockerfile          imagen para Hugging Face Spaces
├── configs/experiment.yaml  periodos, semillas, hiperparámetros
├── data/samples/       muestras estratificadas
├── notebooks/          análisis exploratorio
├── src/data/            DataZoo, particiones, exclusión de campos
├── src/models/          Random Forest, XGBoost, CNN 1D, Transformer
├── src/evaluation/      métricas y prueba de McNemar
├── tests/               pruebas unitarias
├── results/             métricas versionadas
└── app/                 aplicación Streamlit (5 páginas)
```

Anexo B

Tabla 26

Campos del dataset usados y excluidos

Campo	Uso	Motivo
PPI: tamaños, direcciones y tiempos de 30 paquetes	Entrada	Comportamiento observable del flujo cifrado
BYTES, PACKETS, DURATION en ambos sentidos	Entrada	Estadísticas del flujo
PHIST: histogramas de tamaños y tiempos	Entrada	Distribución agregada de la conexión
PPI_LEN, PPI_DURATION, PPI_ROUNDTRIPS	Entrada	Derivados de la secuencia
CATEGORY (desde el mapa de servicios)	Etiqueta	Las 24 categorías de servicio
TLS_SNI	Excluido	Se usó para etiquetar: revela la respuesta
TLS_JA3	Excluido	Identifica al cliente y se asocia al servicio
SRC_IP, DST_IP, DST_ASN y puertos	Excluido	Identifican servidores o usuarios
TIME_FIRST, TIME_LAST	Solo partición	Definen el mes; no son características

Anexo C

Pseudocódigo del pipeline experimental:

```
1 dataset ← CESNET_TLS_Year22(data_root, size='XS')
2 config ← train='M-2022-9' (20 % validación), test='M-2022-10'
3 X, y ← cargar(config); y ← servicio_a_categoria(y)
4 X ← excluir(X, [SNI, JA3, IP, puertos, ASN])
5 reportar_duplicados(X_train, X_test)
6 para m en [RandomForest, XGBoost, CNN1D, Transformer]:
```

```

7      semilla(42); entrenar(m); pred[m] ← predecir(m, X_test)
8      métricas[m] ← F1 macro, F1 ponderado, exactitud, latencia
9      p ← McNemar(pred[mejor_clásico], pred[Transformer], y_test)
10     para mes en ['M-2022-11', 'M-2022-12']: medir_deriva(mes)
11     guardar(resultados); serializar(modelo_recomendado)

```

El Transformer ligero proyecta cada paquete (tamaño, dirección y tiempo) a 64 dimensiones, suma una codificación posicional aprendida para 30 posiciones, pasa por 2 a 4 capas encoder con 2 a 4 cabezas de atención, promedia la salida y termina en una capa de 24 clases.

Anexo D

Tabla 27

Bocetos de las páginas de la aplicación web

Página	Contenido y disposición
Inicio	El problema en pocas líneas, tres cifras clave del dataset, esquema del sistema y botón para explorar los datos
Explorador de datos	Filtros por mes y categoría; distribución de las 24 categorías; tamaños de paquete; deriva mes a mes
Arena de modelos	Mejor F1 macro destacado; tabla comparativa; gráfico de F1 frente a latencia; matrices de confusión; resultado de McNemar explicado
Clasificador en vivo	Botón para tomar un flujo de prueba al azar; secuencia de 30 paquetes; predicción frente a etiqueta real; probabilidades por clase; carga de CSV con plantilla
Conclusiones	Modelo recomendado y por qué; limitaciones; trabajo futuro; atribución del dataset