

FICHA DE DECISIÓN TÉCNICA Y ARQUITECTURA

Estudiante	Jairo Jhayya Perlaza · Proyecto Integrador en IA (MIAR0545), Semana 2 · Fecha: 27/09/2026
Proyecto	Análisis comparativo de modelos de aprendizaje automático y arquitecturas Transformer para la clasificación de tráfico de red cifrado sobre el dataset CESNET-TLS-Year22
Se apoya en	Análisis comparativo de algoritmos (Semana 2, cinco técnicas), EDA (Semana 2, muestra del 2 % de sep–dic 2022: 3 133 138 flujos) y Presentación del proyecto (Semana 1)

1. Técnicas de IA seleccionadas


Del Análisis comparativo de algoritmos, que evaluó cinco técnicas, conservo cuatro en dos roles. La LSTM queda como extensión opcional: entrena de forma secuencial, más lenta, y no se espera que supere a la red convolucional en secuencias de solo 30 paquetes.

- **Línea base: Random Forest y XGBoost.** Ensamblajes de árboles sobre las estadísticas del flujo; entrenan en CPU y explican qué variables pesan en cada decisión.
- **Modelos de comparación: red convolucional 1D y Transformer encoder ligero.** La CNN detecta patrones locales en la secuencia de paquetes; el Transformer (2–4 capas, 2–4 cabezas, ≤ 2 M de parámetros, sin preentrenamiento) relaciona cualquier par de paquetes mediante atención.

2. Justificación según los criterios de selección

- **Tipo de problema.** Clasificación supervisada multiclase en 23 categorías de servicio (las que confirmó el EDA), con datos estructurados de dos formas: una tabla de estadísticas por flujo, terreno natural de los árboles, y una secuencia ordenada de hasta 30 paquetes (tamaño, dirección, tiempo), donde el orden importa y por eso se justifican la CNN y el Transformer. Como el dataset no trae el contenido de los paquetes, descarto ET-BERT, YaTC y otros modelos que trabajan sobre bytes.
- **Datos y recursos.** El entrenamiento usa 800 128 flujos de septiembre de 2022, volumen suficiente para redes pequeñas, aunque con un desbalance de 145 a 1 entre la clase mayor (Advertising) y la menor (Virtual assistant, 593 flujos). Los árboles corren en la laptop; la CNN y el Transformer caben en la GPU gratuita de Colab o Kaggle en menos de 2 horas cada uno. Con 90 horas en 6 semanas, un Transformer preentrenado o un modelo de grafos no es viable; uno ligero sin preentrenamiento sí.
- **Interpretabilidad.** Los administradores de red necesitan entender por qué se clasifica un flujo antes de confiar en el modelo. Random Forest y XGBoost ofrecen importancia de variables; las redes profundas son menos transparentes. Por eso la regla de decisión favorece al modelo clásico: la red profunda solo se recomienda si lo supera con la prueba de McNemar ($p < 0,05$) y con latencia de hasta 10 ms por flujo.

3. Arquitectura y conexión con el pipeline de datos del EDA



El EDA confirmó datos completos (100 %, sin nulos ni valores imposibles) y fijó la entrada de ambas ramas. Se excluyen el SNI, la huella JA3 y las IP por identificar la etiqueta o a los usuarios; el ASN, porque filtra la categoría (NMI de 0,43 frente a 0,08 de PPI_LEN, la variable legítima más informativa); y el puerto y el protocolo, porque son constantes (443 y TCP). La rama A recibe las estadísticas del flujo y los histogramas PHIST; seis de ellas son muy asimétricas (coeficiente de asimetría de hasta 936 en BYTES_REV), por eso se transforman con $\log_{10}(1+x)$. La rama B recibe cada flujo como matriz de 30×3 : la mediana es de 11 paquetes y el 51,6 % de las posiciones son relleno, así que el Transformer usa máscara de relleno. Los pesos por clase del EDA y el desbalance justifican F1 macro como métrica principal.

4. Riesgos técnicos y mitigación

- **Secuencias repetidas:** el 30,3 % de los flujos de prueba repite una secuencia vista en entrenamiento (82 % entre los de 3 a 5 paquetes), lo que inflaría el F1. Mitigación: reportar también el F1 sobre la prueba sin secuencias repetidas.
- **Desbalance y deriva:** desbalance de 145 a 1 y deriva moderada (Jensen-Shannon de 0,05 en octubre y 0,06 en noviembre y diciembre). Mitigación: pesos por clase, parada temprana, F1 macro y medición de la caída en noviembre y diciembre.
- **Costo y convergencia del Transformer:** puede no converger con la GPU gratuita. Mitigación: modelo de ≤ 2 M de parámetros, respaldos por época y, si falla, cierre del estudio con tres modelos.

5. Conclusión

Comparar una línea base clásica e interpretable con dos modelos secuenciales ligeros, sobre el mismo pipeline y con decisión estadística, responde la pregunta del proyecto con los datos y recursos disponibles, sin comprometer la transparencia que piden sus usuarios.