

Nombre del proyecto
Análisis comparativo de modelos de aprendizaje automático y arquitecturas Transformer para la clasificación de tráfico de red cifrado sobre el dataset CESNET-TLS-Year22

Profesor	Gladys María Villegas Rugel
Materia	Proyecto Integrador en Inteligencia Artificial
Alumno	Jhayya Perlaza Jairo Wladimir
Fecha	27-sep-2026

Resumen del Proyecto
Este documento compara cinco técnicas de aprendizaje automático candidatas para clasificar tráfico de red cifrado en 23 categorías de servicio: Random Forest, XGBoost, una red convolucional 1D, una LSTM y un Transformer encoder ligero. La comparación usa los criterios de selección vistos en clase (tipo de problema, datos disponibles, recursos e interpretabilidad), la evidencia de la literatura y los resultados reales del EDA. El resultado es la selección de cuatro técnicas en dos roles, que es la decisión que documenta la Ficha de Decisión Técnica.

Actividad	Fecha
- Caracterización del problema de aprendizaje. - Definición de criterios de comparación. - Descripción de las cinco técnicas candidatas. - Evidencia de la literatura. - Matriz de evaluación ponderada. - Selección final y roles. - Riesgos por técnica y protocolo de comparación.	27-sep-2026

Índice general

Introducción.....	3
2. Desarrollo.....	4
2.1 El problema de aprendizaje según el EDA.....	4
2.2 Criterios de comparación.....	4
2.3 Técnicas candidatas.....	5
2.4 Evidencia de la literatura.....	6
2.5 Matriz de evaluación.....	6
2.6 Selección final.....	7
2.7 Riesgos por técnica y mitigación.....	8
2.8 Protocolo de comparación.....	8
Conclusiones.....	10
Referencias bibliográficas.....	11

Introducción

Elegir un algoritmo por moda es uno de los errores más comunes en proyectos de inteligencia artificial. En clasificación de tráfico cifrado el riesgo es mayor, porque durante años se publicaron modelos cada vez más complejos con resultados casi perfectos, y la revisión crítica de 2025 mostró que modelos simples, bien evaluados, rinden lo mismo [2]–[4]. Por eso este análisis parte del problema y de los datos, no de las técnicas.

Comparo cinco técnicas que representan tres familias: ensambles de árboles (Random Forest y XGBoost), redes para secuencias sin atención (red convolucional 1D y LSTM) y redes basadas en atención (Transformer encoder ligero). Cada una se evalúa con los cuatro criterios de selección vistos en la tutoría y con las cifras reales del EDA de esta semana. El documento termina con una decisión explícita: qué técnicas se usan, con qué rol y cómo se decidirá cuál recomendar.

2. Desarrollo

2.1 El problema de aprendizaje según el EDA

El dataset CESNET-TLS-Year22 [1] registra un año de tráfico TLS de una red en producción. El EDA de esta semana, hecho sobre una muestra del 2 % de septiembre a diciembre de 2022, permite describir con precisión qué tiene que resolver el algoritmo.

Tabla 1

Características del problema que condicionan la elección de técnicas

Característica	Valor y fuente
Tipo de tarea	Clasificación supervisada multiclase, con 23 categorías de servicio (EDA, sección 2.6)
Tipo de datos	Estructurados, en dos formas: una tabla de 60 variables por flujo (8 estadísticas, 20 flags y motivos de cierre, 32 valores de histogramas) y una secuencia ordenada de hasta 30 paquetes con tamaño, dirección y tiempo
Contenido de los paquetes	No disponible: el dataset solo trae metadatos, por lo que se descartan de entrada las técnicas que leen bytes
Volumen de entrenamiento	800 128 flujos de septiembre de 2022; 872 731 de octubre para la prueba
Desbalance	144,9 a 1 entre la clase mayor (Advertising) y la menor (Virtual assistant, 593 flujos)
Forma de las variables	Seis variables del flujo con asimetría mayor que 2; secuencia con mediana de 11 paquetes y 51,6 % de posiciones de relleno
Restricciones del proyecto	Seis semanas, 90 horas de trabajo individual, laptop con 16 GB de RAM y GPU gratuita (Colab o Kaggle); latencia objetivo de hasta 10 ms por flujo
Usuarios del resultado	Administradores de red y equipos de seguridad, que necesitan entender por qué se clasifica un flujo antes de confiar en el modelo

La tabla nro. 1 resume lo que el algoritmo debe resolver. Dos rasgos definen casi toda la comparación: los datos tienen una parte tabular y otra secuencial, lo que favorece a familias distintas de modelos, y los recursos son limitados, lo que descarta arquitecturas pesadas aunque sean las más citadas.

2.2 Criterios de comparación

Uso los cuatro criterios de selección revisados en la tutoría. Cada técnica recibe un puntaje de 1 a 5 por criterio, y los cuatro pesan lo mismo, porque en este proyecto ninguno domina a los demás: una técnica muy precisa pero imposible de entrenar en el plazo sirve tan poco como una fácil de entrenar que no se ajusta al problema.

Tabla 2
Criterios de comparación y escala de puntaje

Criterio	Qué se evalúa	Escala	Peso
Tipo de problema	Qué tan bien se ajusta la técnica a una clasificación multiclase sobre datos tabulares y secuencias cortas de paquetes	1 = no se ajusta · 5 = diseñada para este tipo de dato	25 %
Datos disponibles	Si el volumen (800 000 flujos), el desbalance (145 a 1) y la ausencia de bytes le permiten rendir bien	1 = datos insuficientes o inadecuados · 5 = datos idóneos	25 %
Recursos	Cómputo y tiempo: si entrena en la laptop o en la GPU gratuita dentro del plazo y si cumple la latencia de 10 ms	1 = inviable · 5 = holgado	25 %
Interpretabilidad	Si permite explicar a un administrador de red por qué se clasificó un flujo	1 = caja negra · 5 = explicación directa	25 %

La tabla nro. 2 fija cómo se puntúa cada criterio para que la comparación sea verificable y no dependa de preferencias personales.

2.3 Técnicas candidatas

Tabla 3
Descripción de las cinco técnicas evaluadas

Técnica	Cómo funciona	Entrada en este proyecto	Configuración prevista
Random Forest [9]	Entrena muchos árboles de decisión sobre subconjuntos aleatorios de datos y variables, y vota la clase	Tabla de 60 variables por flujo	300 árboles, profundidad libre, pesos por clase
XGBoost [10]	Construye árboles en secuencia, cada uno corrigiendo los errores del anterior (boosting de gradiente)	Tabla de 60 variables por flujo	400 árboles, profundidad 8, tasa de aprendizaje 0,1, histogramas
Red convolucional 1D	Aplica filtros que recorren la secuencia y detectan patrones locales entre paquetes vecinos	Matriz de 30 × 3 por flujo	Dos capas convolucionales (64 y 128 filtros), pooling global, dropout 0,2
LSTM [11]	Red recurrente que lee la secuencia paquete a paquete y conserva una memoria del contexto	Matriz de 30 × 3 por flujo	Una o dos capas de 64 a 128 unidades
Transformer encoder ligero [12]	Usa atención para relacionar cualquier par de paquetes de la secuencia, sin importar la distancia entre ellos	Matriz de 30 × 3 con máscara de relleno	2 capas, 4 cabezas, dimensión 64, sin preentrenamiento, ≤ 2 M de parámetros

La tabla nro. 3 describe las cinco técnicas y cómo encajarían en el pipeline que definió el EDA. Las dos primeras usan la rama tabular y las otras tres, la rama de secuencia. La configuración prevista es deliberadamente pequeña, pensada para los recursos del proyecto.

2.4 Evidencia de la literatura

Tabla 4

Qué dice la literatura reciente sobre cada familia de técnicas

Técnica	Evidencia
Random Forest y XGBoost	Jerabek et al. [3] y Pešek et al. [5] muestran que modelos simples y ligeros, evaluados con rigor, igualan el desempeño de modelos profundos en clasificación de tráfico cifrado. Soukup et al. [6] usan XGBoost sobre este mismo dataset para medir su estabilidad a lo largo de 2022: F1 medio de 0,55 sin reentrenamiento y de 0,86 con reentrenamiento guiado
Red convolucional 1D	Los modelos de referencia del propio grupo CESNET para clasificar sus datasets usan redes convolucionales sobre la secuencia de paquetes, con buenos resultados en TLS y QUIC [7], [8]
LSTM	Es una arquitectura clásica para secuencias [11], pero en este dominio ha quedado desplazada por las convolucionales y los Transformers, que entrenan en paralelo y capturan patrones sin procesar paquete a paquete
Transformer	Los Transformers más citados (ET-BERT, YaTC) necesitan el contenido de los paquetes y un preentrenamiento costoso, y parte de su desempeño proviene de artefactos del contenido [4]. Propuestas recientes como NT-Transformer [13] prescinden del preentrenamiento, lo que abre la puerta a una versión ligera como la de este proyecto

La tabla nro. 4 muestra que la literatura no da un ganador claro. Los ensambles de árboles son la referencia más sólida por su relación entre costo y desempeño, las convolucionales son el estándar del grupo que creó el dataset y el Transformer es la pregunta abierta: si una versión ligera, sin contenido de paquetes ni preentrenamiento, aporta algo frente a las demás.

2.5 Matriz de evaluación

Tabla 5

Puntaje por criterio (1 a 5) y total ponderado

Técnica	Tipo de problema	Datos disponibles	Recursos	Interpretabilidad	Total
Random Forest	4	5	5	4	4,50
XGBoost	4	5	5	4	4,50
Red convolucional 1D	5	4	4	2	3,75
LSTM	4	4	3	2	3,25
Transformer encoder ligero	5	4	3	2	3,50

La tabla nro. 5 resume la evaluación. Los ensambles de árboles obtienen el total más alto (4,50) gracias a su bajo costo y a su interpretabilidad. Entre las redes, la convolucional encabeza (3,75), seguida por el Transformer (3,50) y la LSTM (3,25). La justificación de cada puntaje está en la Tabla 6.

Tabla 6
Justificación de los puntajes por técnica

Técnica	Justificación por criterio
Random Forest	Problema (4): muy bueno con tablas, pero ve la secuencia solo como columnas sueltas. Datos (5): 800 000 flujos bastan y admite pesos por clase. Recursos (5): entrena en minutos en la laptop y predice en microsegundos. Interpretabilidad (4): importancia de variables directa, aunque con 300 árboles no hay una regla única
XGBoost	Problema (4): igual que Random Forest. Datos (5): maneja bien el desbalance con pesos por muestra. Recursos (5): el método de histogramas lo hace rápido en CPU. Interpretabilidad (4): importancia de variables y explicaciones por flujo con valores SHAP
Red convolucional 1D	Problema (5): diseñada para detectar patrones locales en secuencias, justo lo que muestra la firma de paquetes del EDA. Datos (4): el volumen alcanza, aunque las clases pequeñas (593 flujos) exigen pérdida ponderada. Recursos (4): entrena en la GPU gratuita en menos de 2 horas. Interpretabilidad (2): se puede ver qué posiciones activan los filtros, pero sin explicación directa
LSTM	Problema (4): adecuada para secuencias, pero el orden estrictamente secuencial aporta poco con solo 30 pasos. Datos (4): igual que la convolucional. Recursos (3): procesa paquete a paquete y no se paraleliza, lo que la hace la red más lenta de entrenar. Interpretabilidad (2): caja negra
Transformer encoder ligero	Problema (5): relaciona cualquier par de paquetes y maneja el relleno con máscara, útil porque el 51,6 % de las posiciones son relleno. Datos (4): sin preentrenamiento necesita volumen, que aquí existe. Recursos (3): más costoso que la convolucional, viable solo con un tamaño de hasta 2 M de parámetros. Interpretabilidad (2): los pesos de atención dan pistas, pero no son una explicación fiable

La tabla nro. 6 hace explícito el razonamiento detrás de cada número. Las diferencias más importantes están en recursos e interpretabilidad, donde los ensambles de árboles aventajan con claridad a las redes.

2.6 Selección final

La matriz no se usa para quedarse solo con el primero. El proyecto es un estudio comparativo, así que necesito al menos una técnica por familia relevante. Con ese criterio, la decisión es la siguiente.

Tabla 7
Técnicas seleccionadas y su rol en el proyecto

Técnica	Rol	Motivo
Random Forest	Línea base	Máximo puntaje, costo mínimo e interpretabilidad; es la referencia contra la que se mide todo lo demás
XGBoost	Línea base	Mismo puntaje que Random Forest y usado sobre este dataset por la literatura [6], lo que permite contrastar resultados
Red convolucional 1D	Comparación	La red mejor puntuada y el estándar del grupo que creó el dataset
Transformer encoder ligero	Comparación	Responde la pregunta de investigación: si la atención aporta algo sin contenido de paquetes ni preentrenamiento
LSTM	Opcional	Menor puntaje, sobre todo por costo; se entrena solo si sobra tiempo en el sprint 3, sin formar parte del compromiso

La tabla nro. 7 documenta la decisión central del proyecto, la misma que recoge la Ficha de Decisión Técnica. Se usan cuatro técnicas en dos roles, y la LSTM queda como extensión opcional. La regla de recomendación final favorece

a la línea base: una red profunda solo se recomienda si la supera con significancia estadística (prueba de McNemar, $p < 0,05$) [14], [15] y con una latencia de hasta 10 ms por flujo.

2.7 Riesgos por técnica y mitigación

Tabla 8

Riesgos técnicos de las técnicas seleccionadas

Técnica	Riesgo	Mitigación
Random Forest y XGBoost	Sobreajuste a secuencias repetidas: el 30,3 % de la prueba repite una secuencia de entrenamiento	Reportar el F1 también sobre la prueba sin secuencias repetidas
Random Forest y XGBoost	Variables con colas muy largas (asimetría de hasta 936)	Transformación $\log_{10}(1 + x)$ antes del entrenamiento
Red convolucional 1D	Clases pequeñas mal aprendidas por el desbalance de 145 a 1	Pérdida ponderada con los pesos del EDA y parada temprana en validación
Transformer ligero	No converger en el tiempo o con la GPU gratuita	Modelo de hasta 2 M de parámetros, respaldos por época y, si falla, cierre del estudio con tres modelos
Transformer ligero	Atender a posiciones de relleno (51,6 % de la secuencia)	Máscara de relleno y pooling promedio solo sobre posiciones reales
Todas	Envejecimiento del modelo por deriva (Jensen-Shannon de 0,05 a 0,06)	Medir la caída de F1 en noviembre y diciembre

La tabla nro. 8 asocia cada riesgo a la técnica que lo sufre y a una respuesta concreta. Todos los riesgos provienen de hallazgos del EDA, así que no son supuestos genéricos.

2.8 Protocolo de comparación

Para que la comparación sea justa, las cuatro técnicas se entrenarán y evaluarán en las mismas condiciones:

- Las mismas particiones por mes (septiembre para entrenar, con 20 % de validación; octubre para probar; noviembre y diciembre para la deriva) y la misma semilla.
- Las mismas métricas: F1 macro como métrica principal, F1 ponderado, exactitud, precisión y recall por clase, latencia por flujo en CPU, número de parámetros y tiempo de entrenamiento.
- F1 macro reportado de dos formas: sobre toda la prueba y sobre la prueba sin secuencias repetidas.
- Prueba de McNemar entre el mejor modelo de la línea base y el mejor modelo profundo, con $\alpha = 0,05$.

- Ajuste de hiperparámetros ligero y equivalente para todos, con el mismo presupuesto de tiempo, para no favorecer a ninguna técnica.

Conclusiones

- El problema combina datos tabulares y secuencias cortas de paquetes, sin acceso al contenido. Eso descarta desde el inicio a los modelos basados en bytes, como ET-BERT o YaTC, pese a ser los más citados.
- Con los cuatro criterios de selección, Random Forest y XGBoost obtienen el mayor puntaje (4,50) por su bajo costo y su interpretabilidad; entre las redes, la convolucional 1D (3,75) supera al Transformer ligero (3,50) y a la LSTM (3,25).
- Se seleccionan cuatro técnicas en dos roles: Random Forest y XGBoost como línea base, y la red convolucional 1D y el Transformer ligero como comparación. La LSTM queda como opcional.
- La decisión final favorece a la solución simple: el Transformer solo se recomendará si supera a la línea base con significancia estadística y dentro de la latencia exigida, en coherencia con la evidencia de la literatura reciente.

Referencias bibliográficas

- [1] K. Hynek, J. Luxemburk, J. Pešek, T. Čejka y P. Šiška, "CESNET-TLS-Year22: A year-spanning TLS network traffic dataset from backbone lines," *Sci. Data*, vol. 11, 2024, doi: 10.1038/s41597-024-03927-4.
- [2] N. Wickramasinghe et al., "SoK: Decoding the enigma of encrypted network traffic classifiers," en *Proc. IEEE Symp. Secur. Privacy (S&P)*, 2025.
- [3] K. Jerabek, J. Luxemburk, R. Plný, J. Koumar, J. Pešek y K. Hynek, "When simple model just works: Is network traffic classification in crisis?," *arXiv:2506.08655*, 2025.
- [4] Y. Zhao, G. Dettori, M. Boffa, L. Vassio y M. Mellia, "The sweet danger of sugar: Debunking representation learning for encrypted traffic classification," en *Proc. ACM SIGCOMM*, 2025, pp. 296–310.
- [5] J. Pešek, J. Luxemburk y K. Hynek, "Lightweight traffic classification: A simple baseline matching deep learning performance," en *Proc. 9th Netw. Traffic Meas. Anal. Conf. (TMA)*, 2025, pp. 1–4.
- [6] D. Soukup, R. Plný, D. Vašata y T. Čejka, "Drift-based dataset stability benchmark," *arXiv:2512.23762*, 2025.
- [7] J. Luxemburk y T. Čejka, "Fine-grained TLS services classification with reject option," *Comput. Netw.*, vol. 220, art. 109467, 2023, doi: 10.1016/j.comnet.2022.109467.
- [8] J. Luxemburk, K. Hynek y T. Čejka, "Encrypted traffic classification: The QUIC case," en *Proc. 7th Netw. Traffic Meas. Anal. Conf. (TMA)*, 2023, pp. 1–10, doi: 10.23919/TMA58422.2023.10199052.
- [9] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.
- [10] T. Chen y C. Guestrin, "XGBoost: A scalable tree boosting system," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794.
- [11] S. Hochreiter y J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [12] A. Vaswani et al., "Attention is all you need," en *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [13] Z. Yan, L. Peng, P. Liu, Y. Bao y B. Yang, "NT-Transformer: A non-pretrained encrypted network traffic classification model," *IEEE Trans. Netw. Serv. Manag.*, 2026, doi: 10.1109/TNSM.2026.3683410.
- [14] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
- [15] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Comput.*, vol. 10, no. 7, pp. 1895–1923, 1998.