

Nombre del proyecto
Análisis comparativo de modelos de aprendizaje automático y arquitecturas Transformer para la clasificación de tráfico de red cifrado sobre el dataset CESNET-TLS-Year22

Profesor	Gladys María Villegas Rugel
Materia	Proyecto Integrador en Inteligencia Artificial
Alumno	Jhayya Perlaza Jairo Wladimir
Fecha	27-sep-2026

Resumen del Proyecto
Este documento presenta el análisis exploratorio de datos (EDA) del dataset CESNET-TLS-Year22, que registra 507 739 073 flujos de tráfico TLS de una red en producción durante 2022. El análisis combina las estadísticas diarias de todo el año con una muestra aleatoria del 2 % de septiembre a diciembre (3 133 138 flujos). Sus resultados fijan las variables de entrada, las exclusiones, el preprocesamiento y los riesgos que sustentan la Ficha de Decisión Técnica del proyecto.

Actividad	Fecha
- Obtención y verificación del dataset. - Muestreo reproducible por meses. - Calidad de datos y distribución de clases. - Variables del flujo y secuencia de paquetes. - Fuga de información y secuencias repetidas. - Deriva temporal. - Especificación de entrada para los modelos.	27-sep-2026

Índice general

Introducción.....	3
2. Desarrollo.....	4
2.1 Objetivo y alcance del EDA.....	4
2.2 Obtención y verificación de los datos.....	4
2.3 Metodología y muestreo.....	4
2.4 Panorama del año completo.....	5
2.5 Calidad de los datos.....	8
2.6 Distribución de clases.....	8
2.7 Representatividad de la muestra.....	11
2.8 Variables estadísticas del flujo.....	11
2.9 Secuencia de los primeros 30 paquetes.....	13
2.10 Fuga de información.....	14
2.11 Secuencias repetidas entre entrenamiento y prueba.....	15
2.12 Deriva temporal en la muestra.....	16
2.13 Especificación de entrada para los modelos.....	16
Conclusiones.....	18
Referencias bibliográficas.....	19
ANEXOS.....	20

Introducción

Antes de entrenar cualquier modelo conviene conocer bien los datos. En clasificación de tráfico cifrado esto pesa todavía más, porque la literatura reciente mostró que varios resultados casi perfectos se debían a problemas en los datos y no a la calidad de los modelos: muestras repetidas entre entrenamiento y prueba, campos que delatan la etiqueta y particiones aleatorias que ocultan cómo cambia el tráfico con el tiempo [3], [4].

Por eso este EDA no se limita a describir variables. Busca responder preguntas concretas que afectan el diseño experimental: si los datos están completos, cuántas clases hay realmente y qué tan desbalanceadas están, qué variables necesitan transformarse, qué campos deben excluirse por fuga de información, cuántos flujos de prueba repiten secuencias ya vistas en entrenamiento y cuánto cambia el tráfico de un mes a otro.

Todo el análisis es reproducible. Los datos se obtuvieron del registro oficial del dataset en Zenodo, la muestra se generó con un script con semilla fija y cada cifra de este documento proviene del notebook del EDA, sin valores escritos a mano.

2. Desarrollo

2.1 Objetivo y alcance del EDA

El objetivo es caracterizar el dataset CESNET-TLS-Year22 para fijar, con evidencia, las condiciones de entrada de los cuatro modelos del proyecto: Random Forest y XGBoost como línea base, y una red convolucional 1D y un Transformer encoder ligero como modelos de comparación. El alcance cubre el año completo a nivel de conteos y el periodo de septiembre a diciembre de 2022 a nivel de flujos, que es el periodo del diseño experimental: septiembre para entrenar, octubre para probar, y noviembre y diciembre para medir la deriva.

2.2 Obtención y verificación de los datos

El servidor de descargas de la librería DataZoo (liberouter.org) estuvo fuera de servicio durante la preparación del EDA, con errores 503 y tiempos de espera agotados. Por eso descargué el dataset completo desde su registro oficial en Zenodo, publicado por los mismos autores [1], [2]. La Tabla 1 resume el archivo obtenido.

Tabla 1

Datos obtenidos y verificación de integridad

Elemento	Detalle
Fuente	Zenodo, DOI 10.5281/zenodo.10608607 (licencia CC BY 4.0)
Archivo	CESNET-TLS-Year22.zip, 30 491 259 088 bytes (28,4 GB)
Integridad	MD5 d0dd7c84e2140bba362f6bd23de5cab7, igual al publicado en Zenodo
Estructura	1 203 archivos organizados por semana y día: un CSV comprimido con xz por día (flows-AAAAMMDD.csv.xz) y un resumen diario en JSON (stats-AAAAMMDD.json)
Mapa de servicios	servicemap.csv, descargado aparte de Zenodo: relaciona cada servicio con su categoría
Columnas por flujo	45: identificadores y direcciones, campos TLS (SNI y JA3), estadísticas del flujo, 16 flags TCP, 4 motivos de cierre, la secuencia de los primeros 30 paquetes (PPI), 4 histogramas (PHIST) y las etiquetas APP y CATEGORY

La tabla nro. 1 documenta de dónde salen los datos y cómo se comprobó que llegaron completos. La suma MD5 coincide con la del registro oficial, así que el archivo no sufrió cambios ni cortes durante las casi cuatro horas de descarga.

2.3 Metodología y muestreo

El análisis usa dos fuentes. La primera son los 357 resúmenes diarios en JSON, que cuentan los flujos de cada servicio y permiten ver el año completo sin

leer los flujos. La segunda es una muestra aleatoria del 2 % de los flujos de septiembre a diciembre. Elegí el 2 % porque es la misma proporción de la submuestra XS de DataZoo (10 millones de 507,7 millones) y porque cabe con holgura en la memoria del equipo de trabajo (16 GB de RAM).

El script de extracción lee cada día directamente del zip, sin descomprimirlo en disco, y conserva cada flujo con probabilidad 0,02 usando una semilla fija (42), de modo que la muestra se puede regenerar idéntica. Cinco días de diciembre no tienen flujos en el dataset original (12, 13, 29, 30 y 31) y quedaron registrados como vacíos. La Tabla 2 compara la muestra con la población de cada mes.

Tabla 2

Población y muestra por mes

Mes	Flujos en el dataset	Flujos en la muestra	Fracción	Días	Días vacíos
Septiembre	39 995 390	800 128	2,001 %	30	0
Octubre	43 657 026	872 731	1,999 %	31	0
Noviembre	46 096 524	922 269	2,001 %	30	0
Diciembre	26 894 659	538 010	2,000 %	31	5
Total	156 643 599	3 133 138	2,000 %	122	5


La tabla nro. 2 confirma que la fracción real es del 2,00 % en los cuatro meses. La muestra final tiene 3 133 138 flujos y 190 columnas: 800 128 de septiembre para entrenar, 872 731 de octubre para probar y 1 460 279 de noviembre y diciembre para medir la deriva.

2.4 Panorama del año completo

Los resúmenes diarios suman 507 739 073 flujos de 180 servicios, agrupados en 23 categorías. El mapa oficial de servicios cubre los 180 servicios, así que ninguno quedó sin categoría. En promedio se registraron 1 391 066 flujos por día, con un máximo de 2 770 538.

Figura 1


Flujos registrados por día durante 2022



La figura nro. 1 muestra un ciclo semanal muy marcado: los días laborables superan con claridad a los fines de semana. También se ven los periodos de vacaciones académicas (enero, julio y agosto), con menos tráfico, y algunos días sin registros a inicios de febrero y a fines de diciembre. Los meses del diseño experimental, sombreados, tienen un volumen alto y estable.

Figura 2


Participación de cada categoría por mes (año completo)



La figura nro. 2 compara la mezcla de categorías mes a mes. Las categorías grandes mantienen una participación parecida durante el año, pero hay cambios visibles que justifican medir la deriva en lugar de suponer que el tráfico es estable.

Figura 3

Distancia de Jensen-Shannon de cada mes frente a septiembre



La figura nro. 3 cuantifica esos cambios. Frente a septiembre, los meses más distintos son julio (0,086) y agosto (0,085), en plenas vacaciones, mientras que octubre es el más parecido (0,051). Que el mes de prueba sea el más cercano

al de entrenamiento es coherente con el diseño: la prueba evalúa al modelo recién entrenado, y noviembre y diciembre (0,062 y 0,061) miden su envejecimiento.

2.5 Calidad de los datos

Tabla 3

Verificaciones de calidad sobre la muestra

Verificación	Resultado
Complejidad (celdas sin valores faltantes)	100,0 %
Columnas con valores nulos	Ninguna
Duraciones negativas	0
Bytes negativos	0
Longitud de secuencia (PPI_LEN) fuera de 1 a 30	0
PPI_LEN distinta al número real de paquetes en la secuencia	0
Flujos con menos paquetes que su secuencia	0
Tamaños de paquete fuera de 0 a 1500 bytes	0
Protocolo de transporte	TCP en el 100 % de los flujos
Filas duplicadas exactas	0,0005 %

La tabla nro. 3 resume las comprobaciones de calidad. No hay valores faltantes ni imposibles, y las columnas son coherentes entre sí: la longitud declarada de cada secuencia coincide siempre con los paquetes que realmente contiene. Esto significa que no hace falta imputar ni limpiar datos. Los duplicados exactos son prácticamente nulos, aunque, como se verá en la sección 2.11, eso no descarta que se repitan secuencias de paquetes.

2.6 Distribución de clases

La variable objetivo es CATEGORY. Las 23 categorías aparecen en entrenamiento, en prueba y en los meses de deriva, así que ninguna clase queda sin ejemplos para evaluar. Esta cifra corrige las 24 categorías que se mencionaban en la planificación inicial: el mapa oficial y los datos confirman 23.

Tabla 4

Flujos por categoría en cada partición de la muestra


Categoría	Entrenamiento	Prueba	Deriva	% entrenamiento
Advertising	85 927	86 806	150 451	10,74 %
Social	80 666	93 866	147 956	10,08 %
Media	67 912	70 156	119 926	8,49 %
Other services	65 032	69 134	119 914	8,13 %
Analytics & Telemetry	64 962	67 381	118 763	8,12 %
Antivirus	60 337	49 586	78 225	7,54 %

Categoría	Entrenamiento	Prueba	Deriva	% entrenamiento
Other APIs	51 568	68 746	116 947	6,45 %
Authentication	46 200	50 715	82 101	5,77 %
Videoconferencing	35 816	35 623	51 290	4,48 %
Mail	32 866	35 140	62 013	4,11 %
File sharing	30 992	33 533	55 859	3,87 %
Search	29 945	32 843	67 253	3,74 %
Software updates	25 232	32 225	50 839	3,15 %
Location	24 008	29 667	51 344	3,00 %
Music	23 213	30 618	49 561	2,90 %
Notifications	17 905	18 287	30 899	2,24 %
Instant messaging	16 557	19 764	31 130	2,07 %
Games	16 264	21 306	32 297	2,03 %
Weather	9 786	11 160	13 831	1,22 %
Information systems	9 609	10 735	19 726	1,20 %
Internet banking	3 902	3 581	6 504	0,49 %
Remote desktop	836	963	1 990	0,10 %
Virtual assistant	593	896	1 460	0,07 %

La tabla nro. 4 muestra un desbalance fuerte. La clase mayor es Advertising (85 927 flujos en entrenamiento, 10,74 %) y la menor es Virtual assistant (593 flujos, 0,074 %): una razón de 144,9 a 1. Solo dos categorías tienen menos de 1 000 flujos en entrenamiento: Remote desktop y Virtual assistant.

Figura 4

Flujos por categoría en entrenamiento (escala logarítmica)



La figura nro. 4 hace visible la caída abrupta de las tres últimas categorías. Con este desbalance, la exactitud sería engañosa, porque un modelo podría acertar mucho ignorando las clases pequeñas. Por eso la métrica principal es F1 macro, que pesa igual a todas las categorías, y el entrenamiento usará los pesos por clase de la Tabla 5.

Tabla 5

Pesos por clase calculados a partir del conjunto de entrenamiento

Categoría	Peso	Categoría	Peso
Advertising	0,405	Software updates	1,379
Social	0,431	Location	1,449
Media	0,512	Music	1,499
Other services	0,535	Notifications	1,943
Analytics & Telemetry	0,535	Instant messaging	2,101
Antivirus	0,577	Games	2,139
Other APIs	0,675	Weather	3,555
Authentication	0,753	Information systems	3,620
Videoconferencing	0,971	Internet banking	8,915
Mail	1,058	Remote desktop	41,613

Categoría	Peso	Categoría	Peso
File sharing	1,123	Virtual assistant	58,665
Search	1,162		

La tabla nro. 5 lista el peso que recibirá cada clase en la función de pérdida, calculado como el total de flujos dividido entre el número de clases por los flujos de cada una. Las categorías grandes pesan menos de 1 y las pequeñas mucho más: un error en Virtual assistant cuenta unas 145 veces más que uno en Advertising.

2.7 Representatividad de la muestra

Para comprobar que la muestra refleja bien la población, comparé la participación de cada categoría en la muestra de septiembre con la de todos los flujos de septiembre según los resúmenes diarios. La mayor diferencia fue de 0,075 puntos porcentuales y la correlación entre ambas distribuciones fue de 1,000. La muestra es, en la práctica, una réplica a escala de la población, así que las conclusiones de este EDA se pueden extender al conjunto completo.

2.8 Variables estadísticas del flujo

Estas variables alimentan a los modelos clásicos. La Tabla 6 resume su distribución en toda la muestra.

Tabla 6

Estadísticos descriptivos de las variables del flujo


Variable	Mediana	P25	P75	P99	Máximo	Asimetría
Duración (s)	1,23	0,20	18,05	313	363	3,4
Bytes cliente → servidor	2 285	1 364	4 200	151 085	2 576 897 342	485,1
Bytes servidor → cliente	5 990	4 360	8 810	3 429 667	18 574 408 388	936,0
Paquetes cliente → servidor	13	10	19	985	2 439 124	400,0
Paquetes servidor → cliente	12	9	20	2 796	12 923 392	910,4
Paquetes en la secuencia	11	8	19	30	30	0,8
Duración de la secuencia (s)	0,27	0,09	4,02	171	363	5,2
Idas y vueltas	3	2	4	9	15	1,8

La tabla nro. 6 revela colas muy largas. La mediana de bytes del servidor al cliente es de 5 990, pero el máximo supera los 18 000 millones, y su coeficiente de asimetría llega a 936. Seis de las ocho variables tienen asimetría mayor que 2. Por eso la rama tabular aplicará $\log_{10}(1 + x)$ antes del escalado: sin esa

transformación, unos pocos flujos enormes dominarían las distancias y los gradientes.

Figura 5

Distribución por categoría de tres variables del flujo (escala logarítmica)



La figura nro. 5 compara las categorías en escala logarítmica. Hay diferencias claras: Analytics & Telemetry, Antivirus y Software updates tienen flujos cortos y pequeños, mientras Media, Videoconferencing e Instant messaging se extienden mucho más. También hay solapamiento entre varias categorías, lo que anticipa que ninguna variable aislada basta y que el modelo tendrá que combinarlas.

Tabla 7

Pares de variables con correlación de Spearman mayor que 0,9

Variable 1	Variable 2	Spearman
BYTES_REV	PHIST_DST_SIZES_7	0,912
PACKETS	PACKETS_REV	0,901
PACKETS	PPI_LEN	0,913
PACKETS_REV	PPI_LEN	0,928

La tabla nro. 7 identifica las redundancias entre las 40 variables tabulares (las 8 del flujo y los 32 valores de los histogramas). Solo cuatro pares superan 0,9 y todos tienen una explicación natural, como el número de paquetes en ambos sentidos. No se eliminan: los ensambles de árboles toleran variables


correlacionadas, pero la redundancia se tendrá en cuenta al interpretar la importancia de variables.

2.9 Secuencia de los primeros 30 paquetes

La secuencia de paquetes es la entrada de la red convolucional y del Transformer. Cada flujo guarda, para sus primeros 30 paquetes como máximo, el tamaño, la dirección y el tiempo desde el paquete anterior. La mediana es de 11 paquetes y la media de 14,51; el 20,18 % de los flujos llega al tope de 30 y ninguno tiene menos de 3.

Figura 6


Longitud de la secuencia de paquetes



La figura nro. 6 muestra dos grupos: la mayoría de los flujos tiene entre 5 y 15 paquetes, y un bloque grande llega al máximo de 30, donde la secuencia se corta. En conjunto, el 51,62 % de las posiciones de la matriz de 30×3 son relleno con ceros. Es un dato decisivo para el Transformer: sin una máscara de relleno, el mecanismo de atención le daría peso a posiciones vacías.

Figura 7

Firma media de los primeros 30 paquetes por categoría



La figura nro. 7 resume cómo empieza una conexión típica de cada categoría: los valores positivos son paquetes del cliente al servidor y los negativos, del servidor al cliente. El primer paquete (el saludo TLS del cliente) y el segundo (la respuesta del servidor) son parecidos en todas las categorías; las diferencias aparecen desde el tercero en adelante. Media y Music, por ejemplo, mantienen paquetes grandes del servidor durante toda la secuencia, algo coherente con la transmisión de contenido. Que la información útil esté repartida a lo largo de la secuencia respalda el uso de modelos que la lean completa y en orden.

2.10 Fuga de información

Algunos campos no describen el comportamiento del flujo sino con quién se conecta. Si predicen la categoría casi por sí solos, el modelo aprendería un atajo que no generaliza a otras redes. Medí la información mutua normalizada (NMI) de cada campo con la categoría en el conjunto de entrenamiento. El SNI no se analizó porque es, por construcción, la fuente de la etiqueta.

Tabla 8*Información mutua normalizada de campos candidatos a exclusión*

Campo	Valores distintos	NMI con la categoría	Pureza ponderada
DST_ASN (sistema autónomo de destino)	139	0,430	0,413
DST_PORT (puerto de destino)	1	0,000	—
PPI_LEN (referencia legítima)	—	0,080	—
PPI_ROUNDTRIPS (referencia legítima)	—	0,047	—

La tabla nro. 8 muestra que el ASN de destino comparte mucha más información con la categoría (0,430) que la variable legítima más informativa, la longitud de la secuencia (0,080): más de cinco veces. Con él, el modelo aprendería a reconocer servidores en lugar de patrones de tráfico, y eso no funcionaría en otra red ni cuando los servicios cambien de proveedor. Por eso se excluye. El puerto de destino, en cambio, no filtra nada porque es constante (443 en el 100 % de los flujos), igual que el protocolo (TCP): se excluyen porque no aportan información.

2.11 Secuencias repetidas entre entrenamiento y prueba

Para cada flujo se calculó una huella de su secuencia, combinando tamaño y dirección de los 30 paquetes. Luego medí cuántos flujos de prueba (octubre) tienen una huella idéntica a la de algún flujo de entrenamiento (septiembre). Si ese porcentaje es alto, parte del acierto del modelo podría venir de memorizar secuencias y no de generalizar.

Tabla 9*Flujos de prueba con una secuencia ya vista en entrenamiento, según su longitud*

Longitud de la secuencia	% de prueba repetida en entrenamiento
3 a 5 paquetes	81,76 %
6 a 10 paquetes	48,52 %
11 a 20 paquetes	15,76 %
21 a 30 paquetes	2,31 %
Total de la prueba	30,33 %

La tabla nro. 9 es probablemente el hallazgo más importante del EDA: el 30,33 % de los flujos de prueba repite exactamente una secuencia de entrenamiento. El fenómeno se concentra en los flujos cortos (el 81,76 % entre los de 3 a 5 paquetes) y casi desaparece en los largos (2,31 %). Por categoría, las

más afectadas son Notifications (54,28 %), File sharing (49,84 %) y Analytics & Telemetry (47,85 %), y las menos, Instant messaging (7,82 %) y Virtual assistant (5,47 %). Este resultado coincide con lo reportado por Jerabek et al. [3] y obliga a reportar el F1 de dos formas: sobre toda la prueba y sobre la prueba sin secuencias repetidas.

2.12 Deriva temporal en la muestra

Además de la mezcla de categorías, comparé la distribución de las variables principales entre septiembre y cada mes siguiente con el estadístico de Kolmogorov-Smirnov (KS), que va de 0 (distribuciones idénticas) a 1 (totalmente distintas).

Tabla 10

Deriva frente a septiembre: mezcla de categorías y variables del flujo

Mes	JS categorías	KS BYTES	KS BYTES_R EV	KS DURATIO N	KS PPI_LEN	KS SIZE_0	KS SIZE_1
Octubre	0,050	0,012	0,017	0,024	0,013	0,031	0,032
Noviembre	0,062	0,010	0,015	0,041	0,015	0,028	0,037
Diciembre	0,060	0,015	0,024	0,027	0,010	0,038	0,034

La tabla nro. 10 indica una deriva moderada. La mezcla de categorías cambia algo más en noviembre y diciembre (0,062 y 0,061) que en octubre (0,050), y todos los estadísticos KS de las variables quedan por debajo de 0,05. En otras palabras, el tráfico de los meses siguientes se parece mucho al de septiembre, pero no es idéntico: cambian más las proporciones de categorías que la forma de los flujos. Esto permite evaluar el envejecimiento del modelo en noviembre y diciembre sin que el problema cambie de naturaleza.

2.13 Especificación de entrada para los modelos

Con los hallazgos anteriores quedan fijadas las entradas de las dos ramas del pipeline, que son exactamente las que describe la Ficha de Decisión Técnica.

Tabla 11

Entradas, transformaciones y exclusiones derivadas del EDA

Elemento	Decisión y evidencia
Etiqueta	CATEGORY, 23 clases (sección 2.6)
Particiones	Entrenamiento: septiembre (20 % para validación). Prueba: octubre. Deriva: noviembre y diciembre (sección 2.3)
Rama A: Random Forest y XGBoost	8 variables del flujo, 16 flags TCP, 4 motivos de cierre y 32 valores de histogramas (PHIST). Transformación $\log_{10}(1 + x)$ en las 6 variables muy asimétricas y escalado estándar (sección 2.8)

Elemento	Decisión y evidencia
Rama B: CNN 1D y Transformer	Matriz de 30×3 por flujo: tamaño, dirección y tiempo entre paquetes, con relleno de ceros y máscara de relleno en el Transformer (sección 2.9)
Pesos por clase	Inversos a la frecuencia en entrenamiento (Tabla 5), para compensar un desbalance de 145 a 1
Excluidos	TLS_SNI (fuente de la etiqueta), TLS_JA3 (identifica al cliente), SRC_IP y DST_IP (identifican usuarios y servidores), DST_ASN (fuga, NMI 0,430), DST_PORT y PROTOCOL (constantes), APP (etiqueta fina) y TIME_FIRST (solo para particionar)
Evaluación	F1 macro sobre toda la prueba y sobre la prueba sin secuencias repetidas (sección 2.11); caída de F1 en noviembre y diciembre (sección 2.12)

La tabla nro. 11 es el puente entre este EDA y el modelado. Cada decisión se apoya en una sección de este documento, así que cualquier cambio posterior en los datos se puede rastrear hasta su origen.

Conclusiones

- Los datos son de buena calidad: completitud del 100 %, sin valores imposibles y con columnas coherentes entre sí. La muestra del 2 % (3 133 138 flujos) reproduce la población con una diferencia máxima de 0,075 puntos porcentuales por categoría.
- El problema tiene 23 categorías, no 24 como se planteó al inicio, con un desbalance de 145 a 1. Esto confirma F1 macro como métrica principal y el uso de pesos por clase.
- Seis variables del flujo son muy asimétricas y requieren transformación logarítmica. La secuencia de paquetes tiene una mediana de 11 paquetes y más de la mitad de sus posiciones son relleno, por lo que el Transformer necesita máscara de relleno.
- El ASN de destino filtra la categoría (NMI de 0,430, cinco veces más que la mejor variable legítima) y se excluye; el puerto y el protocolo son constantes.
- El 30,3 % de los flujos de prueba repite una secuencia de entrenamiento, sobre todo entre los flujos cortos. Es el principal riesgo para una evaluación honesta, y por eso el F1 se reportará también sin esos flujos.
- La deriva entre septiembre y los meses siguientes es moderada y se concentra en la mezcla de categorías; los meses de noviembre y diciembre servirán para medir cuánto envejece cada modelo.

Referencias bibliográficas

- [1] K. Hynek, J. Luxemburk, J. Pešek, T. Čejka y P. Šiška, "CESNET-TLS-Year22: A year-spanning TLS network traffic dataset from backbone lines," *Sci. Data*, vol. 11, 2024, doi: 10.1038/s41597-024-03927-4.
- [2] K. Hynek, J. Luxemburk, J. Pešek, T. Čejka y P. Šiška, "CESNET-TLS-Year22," Zenodo, 2024, doi: 10.5281/zenodo.10608607.
- [3] K. Jerabek, J. Luxemburk, R. Plný, J. Koumar, J. Pešek y K. Hynek, "When simple model just works: Is network traffic classification in crisis?," *arXiv:2506.08655*, 2025.
- [4] Y. Zhao, G. Dettori, M. Boffa, L. Vassio y M. Mellia, "The sweet danger of sugar: Debunking representation learning for encrypted traffic classification," en *Proc. ACM SIGCOMM*, 2025, pp. 296–310.
- [5] D. Soukup, R. Plný, D. Vašata y T. Čejka, "Drift-based dataset stability benchmark," *arXiv:2512.23762*, 2025.
- [6] J. Luxemburk y K. Hynek, "DataZoo: Streamlining traffic classification experiments," en *Proc. 2023 Workshop Explainable Safety Bounded Fidelity Mach. Learn. Netw. (SAFE)*, 2023, pp. 3–7.
- [7] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

ANEXOS

Anexo A. Reproducibilidad

El análisis completo se reproduce con los archivos del repositorio del proyecto y estos comandos, ejecutados desde la carpeta del proyecto con el entorno virtual activado:

```
python scripts/01_extraer_muestra.py --zip datasets/CESNET-TLS-Year22.zip
jupyter nbconvert --to notebook --execute --inplace notebooks/01_eda.ipynb
```

Tabla 12

Entorno y archivos del análisis

Elemento	Detalle
Entorno	Python 3.13.15 en entorno virtual; pandas 2.3.3, scikit-learn, SciPy, pyarrow; versiones exactas en requirements-lock.txt (146 paquetes)
Semilla	42 en el muestreo y en todos los submuestreos del notebook
Script de extracción	scripts/01_extraer_muestra.py: muestra reanudable del 2 %, días vacíos registrados, manifiesto por día
Notebook	notebooks/01_eda.ipynb: 11 secciones, todas las cifras calculadas desde los datos
Resultados	results/eda: 13 archivos CSV y JSON, 8 figuras y el resumen resumen_eda.json

Anexo B. Distribución de categorías por mes en el año completo

La matriz completa de participación de cada categoría por mes está en results/eda/categorias_por_mes_anio.csv, y su versión gráfica es la Figura 2.